



ESCUELA DE INGENIERÍA DE FUENLABRADA

GRADO EN INGENIERÍA DE ROBÓTICA SOFTWARE

TRABAJO FIN DE GRADO

Detección de transmisores radiofrecuencia con drones
utilizando aprendizaje por refuerzo.

Autor: Cristian Sánchez Rodríguez

Tutor: Dr. Roberto Calvo Palomino

Curso académico 2023/2024

Agradecimientos

ToDo

Madrid, 30 de junio de 2023

Cristian Sánchez Rodríguez

Resumen

En la actualidad, la ciencia ha avanzado a pasos agigantados con respecto a las soluciones tecnológicas. Especialmente la robótica, también gracias a que abarca una inmensa variedad de campos donde se pueden desarrollar soluciones eficientes y robustas.

Además, ha surgido un nuevo paradigma con el uso de drones, o sistemas aéreos provistos de sensores y actuadores, que amplian el espectro de uso para herramientas tecnológicas, permitiendo abordar los problemas desde nuevas perspectivas. En este proyecto, el foco de estudio se centra en los *Unmanned Air Vehicles* (UAV), ya que se busca automatizar todo el proceso de manejo del mismo.

De este modo, surge la idea de realizar este Trabajo de Fin de Grado (TFG), juntando lo mejor de ambos mundos, soluciones autónomas con dispositivos aéreos tremadamente adaptables a las circunstancias del problema.

Concretamente, el objetivo de este proyecto ha sido demostrar que, empleando aprendizaje por refuerzo (Q-Learning), se puede lograr rastrear y navegar hacia una señal Radio Frecuencia (RF) de forma más efectiva que con el resto de aproximaciones planteadas.

Acrónimos

RAE Real Academia Española

TFG Trabajo de Fin de Grado

UAV *Unmanned Air Vehicles*

UAS *Unmanned Aerial Systems*

GCS *Ground Control Station*

SUAV *Small Unmanned Air Vehicle*

LOS *Line Of Sight*

IA Inteligencia Artificial

RF Radio Frecuencia

ROS *Robot Operating System*

ADC *Analog to Digital Converter*

RSSI *Received Signal Strength Indicator*

SNR *Signal to Noise Ratio*

PLE *Path-Loss Exponent*

AMR *Autonomous Mobile Robot*

AGV *Automated Guided Vehicle*

SAR *Search and Rescue*

VFF *Virtual Force Field*

Índice general

1. Introducción	1
1.1. Robots	2
1.1.1. Drones	3
1.2. Inteligencia artificial	6
1.2.1. Aprendizaje por refuerzo	7
1.3. Vigilancia del espectro electromagnético	8
1.4. Síntesis	9
2. Objetivos	10
2.1. Descripción del problema	10
2.2. Requisitos	11
2.3. Metodología	11
2.4. Plan de trabajo	12
3. Plataformas de desarrollo y herramientas utilizadas	13
3.1. Lenguajes de programación	13
3.1.1. Python	13
3.1.2. C++	14
3.2. <i>Robot Operating System</i> (ROS)	14
3.2.1. Rviz	15
3.3. Gazebo 11	16
3.4. Plataformas de programación	16
3.4.1. Visual Studio Code	16
3.4.2. Github	17
3.5. Módulos	17
3.5.1. OpenCV	17
3.5.2. Matplotlib	18
3.5.3. PX4 autopilot	19
3.6. Iris	20

4. Diseño	21
4.1. Preparación del entorno	21
4.1.1. JdeRobot - drones	21
4.1.2. Teleoperador	22
4.2. Modelo de propagación de señal	26
4.2.1. Aproximación de Friis	27
4.2.2. Módulo python de Friis	28
4.2.3. Aplicación de Friis	29
4.3. Comportamiento sigue señal basado en RF	31
4.3.1. Introducción al problema	31
4.3.2. Algoritmos	32
4.3.3. Experimentos y resultados	38
4.4. Comportamiento sigue señal basado en RF en un entorno dinámico . .	47
4.4.1. Introducción al problema	47
4.4.2. Algoritmos	47
4.4.3. Experimentos y resultados	47
5. Conclusiones	49
5.1. Objetivos cumplidos	49
5.2. Balance global y competencias adquiridas	49
5.3. Líneas futuras	50
6. Anexo	51
Bibliografía	53

Índice de figuras

1.1.	Robótica industrial VS robótica móvil	2
1.2.	Definición de robot	3
1.3.	Historia de los drones	4
1.4.	Descripción gráfica de <i>Unmanned Aerial Systems</i> (UAS) (GCS + Data Links + UAV)	5
1.5.	Clasificación de aprendizaje máquina	7
1.6.	Aprendizaje por refuerzo	7
2.1.	Insights Github por meses TFG	11
3.1.	Esquema de comunicaciones en ROS	15
3.2.	Ejemplo de uso de Rviz	16
3.3.	Simulación dron en Gazebo	16
3.4.	VS Code logo	17
3.5.	Interfaz gráfica usando OpenCV	18
3.6.	Representación de un mapa de calor usando matplotlib	19
3.7.	Controlador PX4	20
3.8.	Iris drone en Gazebo 11	20
4.1.	3DR Iris simulado	22
4.2.	Primera versión del teleoperador	23
4.3.	Versión final del teleoperador	24
4.4.	Tabla ejemplos exponente n	27
4.5.	Primera versión de la interfaz	30
4.6.	Versión final de la interfaz	31
4.7.	Sistemas de referencia	33
4.8.	Representación algoritmo manual	34
4.9.	Representación algoritmo manual optimizado	35
4.10.	Esquema episodio fase de entrenamiento	37
4.11.	Mapa de puntos 30x30 con la señal en la esquina	38

4.12. Trayectorias seguidas en mapa 12x12 con señal en el centro	39
4.13. Gráfico de entrenamiento	39
4.14. Gráficos comparativos	40
4.15. Características de la señal por defecto	40
4.16. Mapa de puntos (12x12), señal centrada	41
4.17. Comparativas (12x12), señal centrada	42
4.18. Mapa de puntos (12x12), señal en la esquina	42
4.19. Comparativas (12x12), señal en la esquina	43
4.20. Mapa de puntos (30x30), señal centrada	43
4.21. Comparativas (30x30), señal centrada	44
4.22. Mapa de puntos (30x30), señal en la esquina	44
4.23. Comparativas (30x30), señal en la esquina	45
4.24. Mapa de puntos (30x30), señales diferentes	46
4.25. Comparativas (30x30), señales diferentes	46
4.26. Simulación de sensor para obstáculo	48

Listado de códigos

3.1. Obtención del parámetro lambda en función de una frecuencia (en este caso 5G)	14
3.2. Hello world en C++	14
4.1. Main de center to center app	25
4.2. Ejemplo básico de uso del módulo Friis	29

Índice de cuadros

6.1. Anexo con las fuentes de donde se han obtenido las imágenes para este proyecto	52
---	----

Capítulo 1

Introducción

En la actualidad, la tecnología forma parte de nuestro día a día. Prácticamente, constituye un elemento imprescindible para llevar a cabo cualquier actividad, sea profesional o cotidiana. Su función consiste en solucionar problemas para hacernos la vida más sencilla.

Con esto en mente, se presenta la **robótica** que, según la Real Academia Española (RAE), se define como “*técnica que aplica la informática al diseño y empleo de aparatos que, en sustitución de personas, realizan operaciones o trabajos, por lo general en instalaciones industriales.*” (Real Academia Española, s.f., definición 2)¹. Sin embargo, no es precisa, por ello una definición más concreta podría ser, ciencia que engloba diversas ramas tecnológicas, encargada del estudio y diseño de dispositivos mecánicos, provistos de sensores y actuadores, capaces de realizar tareas a través de la extracción y posterior procesamiento de la información, con el fin de generar respuestas adecuadas para resolver determinados problemas².

Dentro de la robótica, existen diversas maneras de clasificar, sin embargo, una de las más comunes esta relacionada con la movilidad del dispositivo, esto es, si el mecanismo se puede desplazar por su entorno o no, por tanto se distingue lo siguiente:

1. **Robótica industrial:** que involucra mecanismos fijos, capaces de realizar tareas de manera rápida, precisa y eficiente. Como es el caso de los brazos robóticos³.
2. **Robótica móvil:** la cual abarca a los dispositivos móviles que se engloban en múltiples entornos y aplicaciones, como pueden ser, robótica aérea, terrestre y submarina⁴.

¹<https://dle.rae.es/robótico#WYTncqf>

²<https://revistaderobots.com/robots-y-robotica/que-es-la-robotica/?cn-reloaded=1>

³<https://www.geeksforgeeks.org/industrial-robots/>

⁴<https://www.geeksforgeeks.org/mobile-robots/>

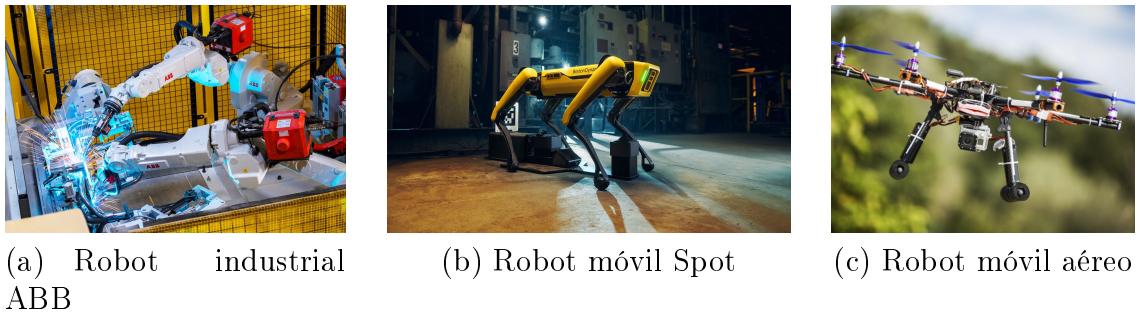


Figura 1.1: Robótica industrial VS robótica móvil

Como tal, la robótica ayuda a resolver tareas repetitivas, peligrosas, delicadas y en ambientes problemáticos (conocidas como las 4 D's, *dull, dirty, dangerous and dear*)⁵. Sin embargo, uno de los problemas más complicados de abordar, es el **contexto**, es decir, la capacidad de entender y adaptarse a las circunstancias del problema, como por ejemplo en el caso de la conducción autónoma, donde detectar un simple peatón, puede derivar en infinitos inconvenientes (condiciones de visibilidad, clima, atuendo, entre muchos otros). Es ahí, donde se presenta el segundo punto importante, la Inteligencia Artificial (IA) [1].

1.1. Robots

Un robot es un dispositivo provisto con **sensores**, o elementos capaces de extraer información del entorno (por ejemplo una cámara), **actuadores**, o elementos que permiten al dispositivo realizar acciones (por ejemplo un motor), y una **unidad de procesamiento**, que se encarga de generar acciones a través de la información obtenida con los sensores, todo ello mediante algoritmos [2].

⁵<https://bernardmarr.com/the-4-ds-of-robotisation-dull-dirty-dangerous-and-dear/>

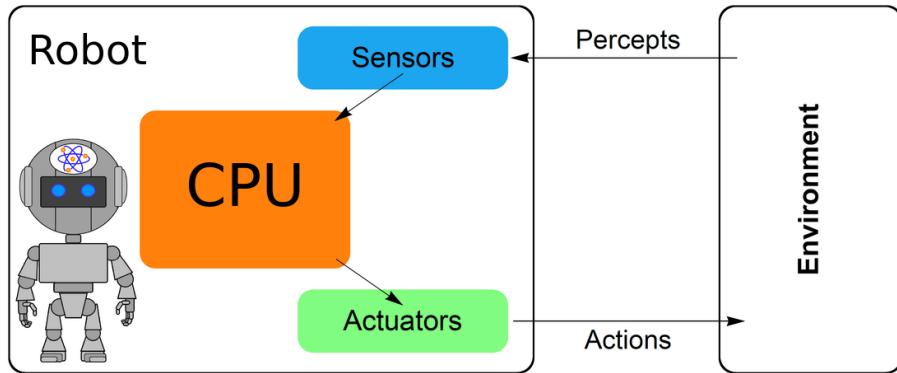


Figura 1.2: Definición de robot

Según el problema que se quiera resolver conviene usar unos u otros. En nuestro caso buscamos un robot con capacidad de navegar, preferiblemente grandes distancias y que pueda tomar medidas de la intensidad de una señal de forma autónoma.

Existen múltiples robots capaces de satisfacer estas condiciones, vease, los *Automated Guided Vehicle* (AGV)/*Autonomous Mobile Robot* (AMR) o plataformas robóticas terrestres ampliamente empleadas logística, que permiten mover mercancía y navegar de forma autónoma por almacenes y naves industriales⁶; los robots bipedos, los cuales emulan el movimiento humanoide, lo que aumenta su adaptabilidad a cualquier entorno real (ya que el mundo esta diseñado para la biomecánica humana), sin embargo, son bastante complejos debido a la dificultad de replicar la marcha bípeda [3]; y por último, los drones, empleados en labores de *Search and Rescue* (SAR), o de inspección en lugares poco accesibles, entre otros.

1.1.1. Drones

Los drones tienen origen en la primera guerra mundial, con el biplano llamado **Kettering bug**. Se trataba de un torpedo que era lanzado desde una carretilla, capaz de volar de forma no tripulada, hasta que se liberaba de sus alas y caía sobre el objetivo⁷. Más tarde, entre la primera y segunda guerra mundial (1935), se diseño el **Queen Bee**, de donde surgió el termino “drone”, como abeja macho en busca de la reina, que se trataba de un avión no tripulado, con el fin de servir de objetivo para realizar prácticas de artillería aérea⁸. Sin embargo, no fue hasta **Operation Aphrodite**, en la

⁶<https://www.mobile-industrial-robots.com/insights/get-started-with-amrs/agv-vs-amr-whats-the-difference/>

⁷<https://www.nationalmuseum.af.mil/Visit/Museum-Exhibits/Fact-Sheets/Display/Article/198095/kettering-aerial-torpedo-bug/>

⁸<https://www.dehavillandmuseum.co.uk/aircraft/de-havilland-dh82b-queen-bee/>

segunda guerra mundial, donde realmente se vió el primer dron radio tripulado, con el fin de poder volar en entornos “sucios” o dirty, dado el nuevo paradigma de las bombas atómicas ⁹.



(a) Kettering Bug



(b) Queen Bee



(c) Aphrodite Operation

Figura 1.3: Historia de los drones

Existen múltiples avances y ejemplos posteriores, pero en la actualidad podemos definir un **UAS** teniendo en cuenta lo siguiente:

1. **Ground Control Station (GCS)**: es la estación de tierra o el elemento encargado de controlar la nave ¹⁰
2. **Comunicación**: conecta y gestiona la transmisión de datos entre el UAV y la GCS, mediante **data links**, o canales de transmisión [4].
3. **UAV**: hace referencia directamente a la aeronave.

⁹<https://warfarehistorynetwork.com/article/operation-aphrodite/>

¹⁰<https://www.trentonsystems.com/blog/ground-control-stations>

¹¹<https://srmconsulting.es/blog/uav-uas-rpa-dron-como-llamarlos.html>

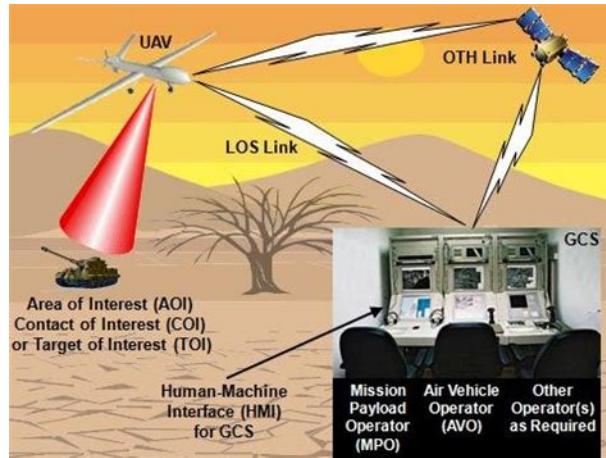


Figura 1.4: Descripción gráfica de UAS (GCS + Data Links + UAV)

También cabe destacar que hay variedad de drones, según su peso y capacidad de carga de pago, o elementos que sea capaz de cargar, lo cual influye en la **legislación** detrás de su uso (de forma general, cuanto mayor sea el peso, más legislación debe cumplir y mayores restricciones de uso tiene)¹².

Tal y como fue mencionado, la gran ventaja del uso de vehículos aéreos es poder evitar las irregularidades del terreno, sin embargo, hay ligados al uso de estos dispositivos ciertos problemas, como son el clima, la carga de pago que afecta a la autonomía (peso de las baterías), los interiores (afectan a la señal GPS), entre otros.

Agrupando la robótica y los drones, se pueden observar múltiples ejemplos de uso, uno muy conocido es el de un dron “*sigue-persona*”, el cual permite a un *Small Unmanned Air Vehicle* (SUAV) detectar y moverse al son de un objetivo móvil, tal y como puede ser una persona; o bien para controlar desastres naturales, como por ejemplo un incendio, donde mediante visión artificial se puedan localizar y controlar los focos activos¹³.

Estos comportamientos, son especialmente complejos debido a que se navega por entornos desconocidos (es decir, sin un mapa disponible), además de estar sujetos a una reactividad elevada, lo que requiere un procesamiento de datos eficiente y una baja latencia en las comunicaciones, lo cual está directamente relacionado con las condiciones del entorno y su contexto.

¹²<https://www.safedroneflying.aero/en/drone-guide/drone-regulations>

¹³<https://www.euronews.com/2023/09/19/could-ai-powered-drones-be-the-solution-to-europe-s-wildfire-problems>

1.2. Inteligencia artificial

La IA ha tenido un auge importante en los últimos años, especialmente en el ámbito de la robótica dado su amplio abanico de soluciones sinérgicas con la misma, desde “*Computing Machinery and Intelligence*” (Alan Turing, 1950), donde se buscó responder fue la siguiente **¿Puede una máquina pensar?**, formulada en “*Computing Machinery and Intelligence*” (Alan Turing, 1950); pasando por **Logic Theorist** en el **Dartmouth Summer Research Project on Artificial Intelligence** [5]; hasta la actualidad, donde los algoritmos mejoraron a la par de la capacidad de computación, destacando por ejemplo la navegación autónoma, empleada en drones entre otros vehículos ¹⁴.

En general, la IA es capaz de abordar los siguientes problemas de aprendizaje:

1. **Supervisado:** es decir, se emplea un conjunto de datos del que se conocen tanto las salidas como las entradas a las que pertenecen. La idea es conseguir obtener una salida precisa dada una entrada concreta. Por ejemplo, para detectar obstrucciones mediante datos etiquetados, en una imagen de un dron [6].
2. **No supervisado:** donde se tiene un conjunto de datos de entrada de los que no se conoce la salida. Básicamente, se encarga de distribuir dicho conjunto en sets con características comunes. Un ejemplo común es la segmentación de imágenes, donde se clasifica cada elemento de la imagen según su naturaleza, como puede ser el caso de detectar turbinas defectuosas o no defectuosas, en aeronaves empleando reconocimiento por imagen [7].
3. **Por refuerzo:** resuelve un problema a base de prueba y error, mediante un sistema de recompensas. Como por ejemplo “*Stockfish*”, que es un modelo entrenado para ganar una partida de ajedrez en el menor número de movimientos posible, superando incluso a grandes maestros de la actualidad ¹⁵, o por ejemplo, en un caso más relacionado, para mejorar la navegación en drones [8].

¹⁴<https://sitn.hms.harvard.edu/flash/2017/history-artificial-intelligence/>

¹⁵<https://stockfishchess.org/about/>

¹⁶<https://www.springboard.com/blog/data-science/regression-vs-classification/>

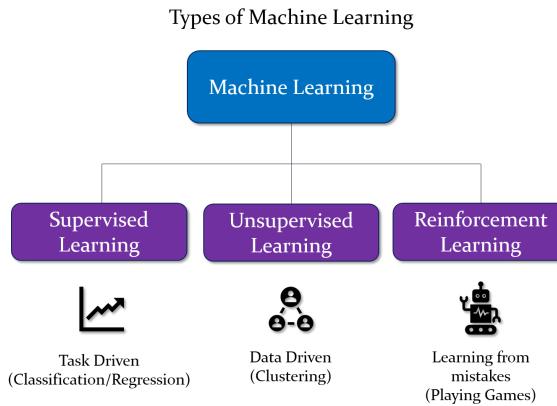


Figura 1.5: Clasificación de aprendizaje máquina

1.2.1. Aprendizaje por refuerzo

Se basa en un sistema de **recompensas y penalizaciones**, que permite entrenar a un modelo para converger hacia la toma de buenas decisiones. Este enfoque se basa en los llamados **procesos de Markov**, que se definen como aquellos que, para un instante dado, contienen toda la información relevante sin depender de todos los procesos anteriores.¹⁷

En particular, hablamos de **agente**, o modelo encargado de tomar decisiones en un **entorno** (que es el medio en el que interactúa dicho agente, y está regido por una serie de reglas); **estados**, o circunstancias en la que se sitúa el agente en un determinado instante temporal; y **acciones**, o decisiones que toma el agente y que le permiten cambiar de estado. En términos de Markov, decimos que el estado actual no depende de todos los estados previos.¹⁸

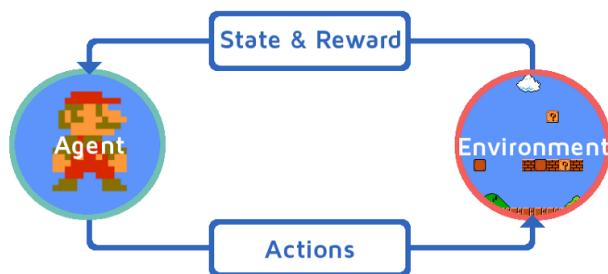


Figura 1.6: Aprendizaje por refuerzo

¹⁷<https://www.geeksforgeeks.org/what-is-reinforcement-learning/>

¹⁸<https://www.alexanderthamm.com/es/blog/refuerzo-aprendizaje-marco-y-ejemplo-de-aplicacion/>

Cabe destacar que, este enfoque está directamente extraido de la **psicología** y el estudio del comportamiento, donde en función de recompensas y castigos se induce al aprendizaje en distintas tareas, como por ejemplo, enseñar a jugar al ping pong a dos palomas¹⁹, o más en relación a aplicaciones con aeronaves, para obtener rutas óptimas en carreras de drones [9].

Entre los distintos modelos, encontramos **Q-Learning**, que busca generar una tabla numérica donde cada fila se interprete como un estado del robot, que puede ser su posición; y cada columna sea una determinada acción, como puede ser moverse hacia algún lugar. De este modo, y a través de una **función de recompensa**, se llenan los valores de la tabla, los cuales, según el tipo de función escogida, convergerá comportamientos de un tipo u otro. Una vez obtenida la tabla, el robot solo debe identificar en qué estado se encuentra (fila) y elegir la columna con mayor valor numérico, lo que se traducirá en la mejor acción para dicho estado²⁰.

Existen múltiples ejemplos de aplicación de esta metodología a casos reales, vease para controlar de forma adaptativa una señal de tráfico; para jugar a la Atari 2600; o para realizar un control híbrido sobre la navegación de un Robot [10]; o para seleccionar qué vehículos reduce costes y mejorar la eficiencia, de cara a entregar mercancía (vía aerea empleando drones o vía terrestre) [11].

1.3. Vigilancia del espectro electromagnético

Las comunicaciones inalámbricas son aquellas donde tanto el emisor como el receptor se intercambian información mediante ondas electromagnéticas. En su defecto usan ondas electromagnéticas moduladas transmitidas generalmente por el aire. En este caso concreto, hablamos de señales RF, como son por ejemplo Wi-Fi, radio FM, 4G, 5G, entre otros tipos de señales distribuidas a lo largo del espectro.

Dicho espectro se divide por bandas de frecuencia, que se reparten para diversos uso. El ejemplo más claro es la banda FM de radio, que se reparte entre los 87-108 MHz para España, donde cada emisora tiene un ancho asignado para emitir, o por ejemplo la banda GPS, dispuesta para el posicionamiento, situada en 1565 MHz, o también la

¹⁹<https://pressbooks.online.ucf.edu/lumenpsychology/chapter/operant-conditioning/>
<https://pressbooks-dev.oer.hawaii.edu/psychology/chapter/operant-conditioning/>

²⁰<https://towardsdatascience.com/reinforcement-learning-explained-visually-part-4-q-learning->

banda GSM, que distribuye la telefonía móvil y se encuentra entre 900 y 1800 MHz.²¹

De este modo, se pueden encontrar soluciones a problemas como el rastreo de una señal de móvil para una persona perdida en la montaña, o seguir emisores concretos, como pueden ser convoys, o también en casos de ataques del tipo jamming (introducción de interferencias para invalidar la comunicación), donde se necesite hallar el origen del ataque, entre otros. Lo único que hay que establecer, es la banda de frecuencia adecuada y establecer un comportamiento que permita navegar hasta la señal de manera autónoma. Otro ejemplo de uso, es para mejorar la localización en robots, mediante el uso de redes 5G [12]

1.4. Síntesis

Este proyecto se centra en desarrollar un comportamiento autónomo de un dron, basado en aprendizaje por refuerzo, con el fin de detectar el origen de una señal RF en un entorno dinámico, esto es, un escenario con obstáculos sobre el cual se navegue hasta la fuente de la señal.

²¹https://www.wikiwand.com/en/FM_broadcast_band

Capítulo 2

Objetivos

En este capítulo se tratará el propósito de este proyecto, así como los requerimientos, el método seguido y la estructura del mismo.

2.1. Descripción del problema

Los drones son una herramienta tremadamente versátil, ya que permiten solventar los inconvenientes orográficos de forma sencilla, y pueden ser provistos de múltiples sensores, lo que incrementa su adaptabilidad para solucionar un gran abanico de retos ingenieriles.

Por tanto, el foco de este TFG consistirá en desarrollar un comportamiento autónomo en un dron, para detectar y localizar el origen de una señal RF. Esto puede ser especialmente útil en labores de rastreo e identificación de objetivos, tales como en casos de escenarios catastróficos donde se deben localizar personas perdidas o de rastreo de señales en entornos indoor.

Para ello, se establecen los siguientes objetivos:

1. Desarrollo de una aplicación, enfocada a teleoperar un UAV, empleando herramientas de simulación y visualización.
2. Implementación de un modelo de propagación de señales.
3. Desarrollo de un comportamiento autónomo capaz de detectar y navegar hacia la fuente de una señal RF.
4. Comparativa frente a los algoritmos navegación tradicionales.
5. Desarrollo de un comportamiento autónomo en un escenario dinámico.

2.2. Requisitos

Las especificaciones que se deben cumplir son las siguientes:

1. El modelo de propagación de señal debe ser el modelo de Friis.
2. Se debe usar ROS como middleware robótico y Gazebo como herramienta de simulación.
3. Se debe seleccionar el algoritmo que navegue de forma más eficiente.
4. Se debe seleccionar el algoritmo más seguro en cuanto a salvaguardar la integridad del dispositivo y sus alrededores.

2.3. Metodología

Este trabajo, comenzó oficialmente en Septiembre de 2022, aunque se pusieran en común las ideas a principios del verano, y se concluye a finales de Septiembre de 2023.

La metodología para llevarlo a cabo fue la siguiente:

1. Reunión de control semanal o cada dos semanas vía Teams con el tutor, donde se realizaba una valoración del estado del proyecto y se establecían los futuros puntos a seguir.
2. Uso de la metodología Kanban, que es una metodología visual para gestionar y optimizar el flujo de trabajo a través de tarjetas y límites de trabajo en curso.
3. Empleo de la plataforma Github, a fin de establecer un repositorio común¹, como sistema de control de versiones y de almacenamiento de backups.
4. Desarrollo de un blog donde se describe el estado del proyecto².

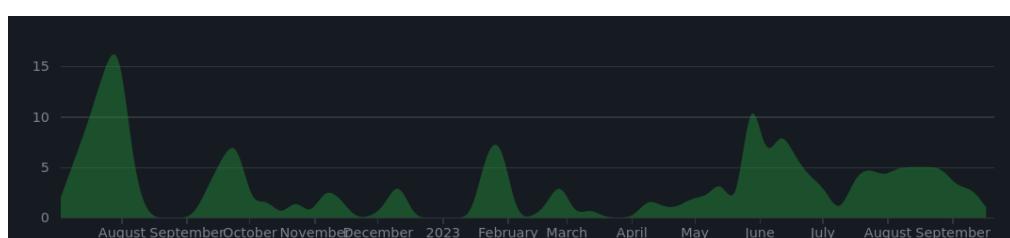


Figura 2.1: Insights Github por meses TFG

¹<https://github.com/RoboticsLabURJC/2022-tfg-cristian-sanchez>

²<https://roboticslaburjc.github.io/2022-tfg-cristian-sanchez/>

2.4. Plan de trabajo

Para concluir este capítulo, los pasos seguidos han sido:

1. Etapa inicial, donde tras establecer los objetivos del proyecto, se empezó por investigar el estado del arte del uso de drones para aplicaciones robóticas.
2. Los primeros pasos en el TFG se centraron realizar una aplicación para teleoperar a un dron.
3. El siguiente punto se basó en el estudio y comprensión de las señales RF dentro del espectro de radiofrecuencia.
4. Posteriormente, se desarrollaron diversas soluciones encargadas de resolver el problema de detectar y navegar hacia una señal.
5. A continuación, se realizó una fase de pruebas y extracción de información sobre la que se realizaron diversas comparativas.
6. Cerrando la fase de desarrollo, lo último fue implementar soluciones sobre escenarios más realistas que incluían obstáculos.
7. Finalmente, se realizó la redacción de la memoria.

Capítulo 3

Plataformas de desarrollo y herramientas utilizadas

En este apartado se hablará de los recursos ingenieriles empleados para hacer posible el proyecto.

3.1. Lenguajes de programación

3.1.1. Python

A día de hoy, es considerado el lenguaje de programación más popular [13]. Se ideó en 1991 por Guido van Rossum y se desarrolló en la Python Software Foundation [14]. Es interpretado, es decir, usa un programa que traduce las líneas de código para la máquina en tiempo de ejecución (lo cual lo hace más intuitivo pero menos eficiente). Además, permite la programación orientada a objetos en alto nivel, lo que ofrece gran dinamismo a la hora de usarlo [15] [16].

Debido a su amplia popularidad, podemos acceder a una gran variedad de módulos y utilidades desarrollados por la comunidad, los cuales se integran perfectamente en la resolución de nuestro problema.

En nuestro caso, python se usó para el crear la mayor parte del código empleado, es decir, para desarrollar interfaces gráficas, para trabajar con el middleware robótico ROS (detallado posteriormente) y para el desarrollo de los diversos algoritmos. Todo ello haciendo uso del módulo **numpy**, el cual nos permite realizar operaciones matemáticas y trabajar con vectores de forma rápida y eficiente; así como del módulo **matplotlib**, del cual hablaremos más adelante.

```
#! /usr/bin/env python

if __name__ == "__main__":
    C = 3.0 * (10 ** 8)
    freq = 5 * (10 ** 9)
    lmbda = C / freq
```

Código 3.1: Obtención del parámetro λ en función de una frecuencia (en este caso 5G)

3.1.2. C++

También bastante popular, se encuentra el lenguaje de programación creado por Bjarne Stroustrup, en los laboratorios Bell en 1971. En este caso es compilado, lo que implica la traducción y enlazado previo a la ejecución. De corte más eficiente que Python, también permite la programación orientada a objetos. Se sitúa a medio camino entre un lenguaje de alto nivel y uno de bajo nivel [17].

El uso designado en este proyecto para este lenguaje fue para poder trabajar con mapas de calor, mediante la biblioteca de *Anybotics* de grid maps¹.

```
#include <iostream>

int main(int argc, char ** argv) {
    std::cout << "Hello World!" << std::endl;
    return 0;
}
```

Código 3.2: *Hello world* en C++

3.2. ROS

Si se habla de robótica, se habla de ROS, ya que es el framework para el desarrollo de soluciones de este ámbito, pero, ¿qué es exactamente ROS?.

Se trata de un *middleware*, es decir, una infraestructura software situada entre el sistema operativo y el desarrollador, que incluye una serie de módulos y funcionalidades enfocadas al desarrollo de aplicaciones robóticas [18] [19]. La idea detrás, busca estandarizar soluciones que no dependan de los drivers de cada sensor y actuador presentes. De forma general, se trata de una arquitectura basada en el paradigma de

¹https://github.com/ANYbotics/grid_map

publicador-suscriptor, donde una serie de nodos se comunican entre sí, transmitiendo mensajes propios, a través de canales compartidos llamados *topics*, esto es, un nodo suscriptor se suscribirá a un determinado topic, que permita la transmisión de un tipo de mensaje concreto, quedando en espera de que un nodo pulicador, envíe mensajes de este tipo a ese topic. Todo se gestiona de manera centralizada, es decir, existe un master que se encarga de gestionar el registro de todos los nodos a los topics pertinentes.

Concretamente, se usa para desarrollar todos los algoritmos robóticos y para realizar las comunicaciones necesarias en la simulación del dron.

Entre las herramientas usadas en este proyecto, se encuentran las siguientes.

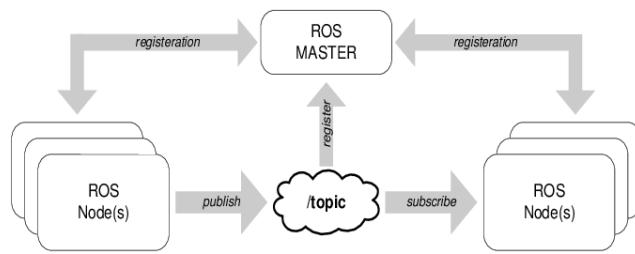


Figura 3.1: Esquema comunicaciones en ROS

3.2.1. Rviz

Por el otro lado, se encuentra *rviz*, que es un visualizador 3D diseñado para la depuración de aplicaciones ROS [20].

En nuestro caso, nos permite ver como se dispersa la señal RF, que trayectoria y orientación sigue el dron, que efecto tiene sobre la señal la presencia de obstáculos, y otras tantas opciones.

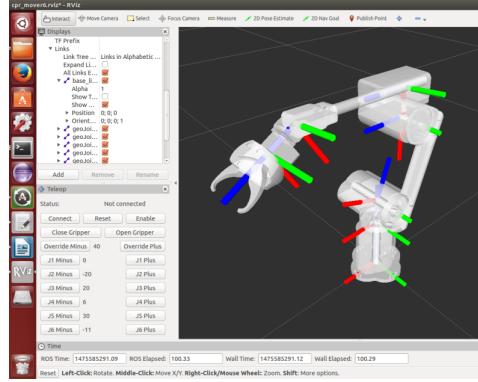


Figura 3.2: Ejemplo de uso de Rviz

3.3. Gazebo 11

Se trata del simulador sobre el cual se desarrolla el proyecto. Concretamente consta de un conjunto de módulos optimizados para desarrollar aplicaciones robóticas, ampliamente compatible con ROS. Además, posee un motor de físicas basado en ODE, lo que permite simular con precisión el funcionamiento de un dron [21].

Esta herramienta, nos permite visualizar en directo, el comportamiento del dispositivo frente a los diversos escenarios que se planteen.



Figura 3.3: Simulación dron en Gazebo

3.4. Plataformas de programación

3.4.1. Visual Studio Code

Entre las plataformas usadas para programar, *Visual Studio Code*, o mejor conocido como *VS code*, es un editor de código ligero, funcional tanto en Linux, Windows y

macOS [22].

Su principal ventaja, es que es altamente personalizable a el tipo de desarrollo software que se deseé realizar. Todo ello a través de las múltiples extensiones que ofrece, así como la conexión directa y fluida con plataformas como Github, que se detallarán a continuación.

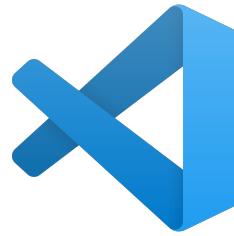


Figura 3.4: VS Code logo

3.4.2. Github

Github nace de la herramienta **git**, creada por Linus Torvalds (desarrollador de Linux), que es un sistema de control de versiones, que funciona a grandes rasgos a través de repositorios (o lugares donde se almacenan los sistemas de versiones de forma local), y commits (que permiten actualizar la versión del código almacenado del repositorio) [23].

De este modo, Github consiste en trasladar la idea de tener repositorios locales, para distribuirlos en una plataforma online, donde además se permite el desarrollo de aplicaciones de manera colaborativa.

Por ello, el papel que toma en este proyecto es de vital importancia, ya que asegura un seguimiento y una seguridad, de cara a tener copias de seguridad, donde todo lo que deseé puede acceder a ver en que punto se encuentra el TFG pueda hacerlo.

3.5. Módulos

3.5.1. OpenCV

Es una biblioteca software de python, enfocada a visión artificial, y que además dispone de otras funcionalidades útiles para el desarrollo [24].

Por tanto, el uso designado en este proyecto es el de implementar interfaces gráficas sencillas, sobre las que interactuar dinámicamente con el dron, a través de barras de acción y botones.

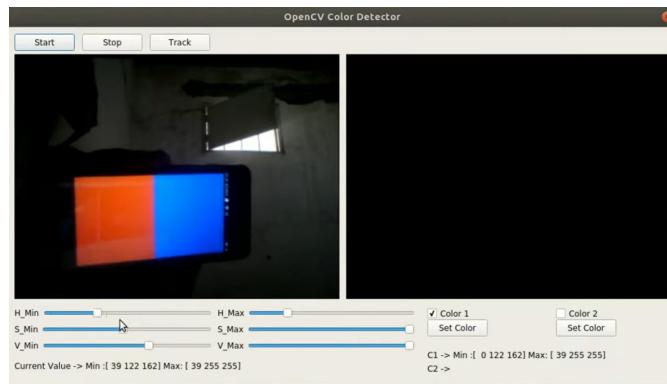


Figura 3.5: Interfaz gráfica usando OpenCV

3.5.2. Matplotlib

Presentada por John Hunter en 2002, se usó como alternativa para el desarrollo de interfaces gráficas. La gran diferencia radica en que está diseñada para trabajar con estructuras numéricas del tipo array (muy compatible con Numpy¹), lo que permite ofrecer una gran visualización y una interfaz responsiva [25].

Concretamente en este proyecto se usa para desarrollar implementar mapas de calor (que en definitiva son estructuras numéricas del tipo array) dentro de una interfaz gráfica, para simular el comportamiento de una señal RF, permitiendo modificar los parámetros de la ecuación en tiempo real.

¹<https://numpy.org/about/>

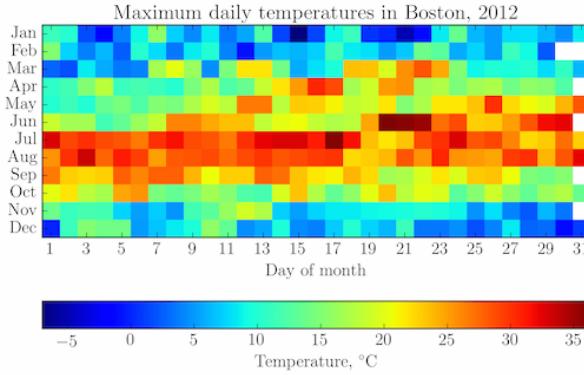


Figura 3.6: Representación de un mapa de calor usando matplotlib

3.5.3. PX4 autopilot

Es la capa de software que permite hacer funcionar las aeronaves con sus componentes, esto es a través del controlador de vuelo, que a efectos prácticos se trata del cerebro del sistema, es decir, interconecta los sensores y actuadores, permitiendo comandar diversas acciones [26] [27].

Este sistema, usa un conocido protocolo de comunicaciones llamado **MAVLink**, que se encarga de gestionar la comunicación entre el controlador de vuelo y la GCS. En nuestro caso, y como queremos desarrollar aplicaciones mediante ROS, debemos añadir una capa más, que se encarga de traducir los mensajes ROS a mensajes compatibles con el protocolo MAVLink, y de esto se encarga **MAVROS** [28] [29].



Figura 3.7: Controlador PX4

3.6. Iris

Es el nombre de la aeronave usada para solucionar los problemas planteados. En síntesis, es un dron cuadracóptero provisto de una cámara y un sensor de RF simulado. Dicha aeronave es cortesía de **JdeRobot**, que es una organización sin ánimo de lucro, asociada a *RoboticsLabURJC*, que provee de un conjunto de herramientas pensadas para desarrollar aplicaciones robóticas [30].

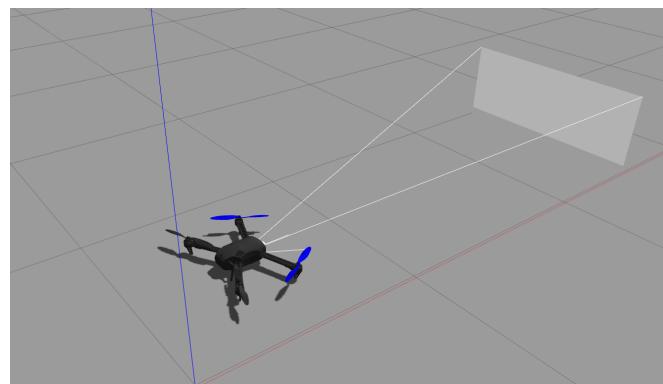


Figura 3.8: Iris drone en Gazebo 11

Capítulo 4

Diseño

En este capítulo se expone, de forma detallada, el proceso seguido para conseguir que un dron detecte y navegue hacia una señal RF.

Además, se muestra el desarrollo de una aplicación resposiva, que simula el comportamiento de una señal (en un espacio libre de obstáculos), basada en la aproximación de Friis.

Por último, se determina cuál de los métodos empleados es mejor y por qué, a través de diversas métricas comparativas.

A continuación, se puede observar un diagrama de bloques donde se ve una vista general del sistema empleado:

(METER DIAGRAMA DE BLOQUES)

4.1. Preparación del entorno

Inicialmente, se pone en funcionamiento el entorno de simulación (compatible con ROS), así como el sistema de control de versiones, para mantener la trazabilidad y los backups. Por ello, se crea un repositorio común en **GitHub** y se instala y prueba el paquete de herramientas dispuesto por **JdeRobot**.

4.1.1. JdeRobot - drones

Gracias a esta plataforma, se obtienen los modelos y los módulos necesarios para simular en Gazebo 11 el desempeño de un cuadracóptero, provisto de un sistema autopilot PX4.

Específicamente, el modelo usado es el **3DR Iris simulado**, con un plugin de una cámara frontal. Este dispositivo utiliza MAVROS para realizar la comunicación, lo que nos permite enviar y recibir mensajes ROS compatibles con el protocolo de comunicaciones típico de estas aeronaves, MAVLink.



Figura 4.1: 3DR Iris simulado

4.1.2. Teleoperador

Una vez es funcional el entorno y los modelos, la primera aproximación ha consistido en realizar una interfaz gráfica simple, para enviar órdenes a la aeronave.

Para ello, se debe conseguir enviar mensajes de forma programática. Por tanto, se diseña un **script controlador** encargado de la comunicación directa con el **controlador de la aeronave**, que a su vez se encarga enviar y recibir diversos datos vía MAVROS. De igual modo, se satisfacen una serie de requisitos para asegurar el correcto funcionamiento del sistema:

1. La comunicación se debe dar a **más de 2Hz**, para evitar cambios indeseados en el funcionamiento interno del controlador PX4 (de la aeronave).
2. Antes de realizar cualquier comunicación, **se debe asegurar que el estado es “connected”**, lo que significa que el dron esta armado y en modo *OFFBOARD* (nuestra aeronave posee 7 modos distintos, *HOLD*, que mantiene la posición, *RETURN*, que vuelve al punto de despegue, *MISSION*, que permite cargar rutas programadas con anterioridad, *TAKEOFF*, habilita el despegue, *LAND*, habilita el aterrizaje, *FOLLOW ME*, que permite seguir objetivos, y *OFFBOARD*, que permite comandar al dron sin necesidad de GPS, lo que es útil de cara al desarrollo de aplicaciones robóticas) [31].

3. Una vez está conectado, se deben **enviar datos** (velocidades en nuestro caso) al controlador PX4, con el fin de **evitar el cierre de la conexión**. Estos datos carecen de utilidad más que la de asegurar dicha conectividad.
4. Por último, y antes de enviar cualquier posición, velocidad o comando (distintos modos de actuación), se debe comprobar siempre que el **modo activo** es *OFFBOARD* y que el dron esta **armado** (listo para volar). En caso contrario, se debe solicitar al controlador, mediante servicios, dichos requerimientos.

Por tanto, la manera de generar comportamientos en el dron en sí, es mediante *topics*. Concretamente, los que genera MAVROS automáticamente cuando se lanza todo el sistema. Tal y como se comentó en apartados anteriores, estos *topics* sólo admiten mensajes ROS, lo que encapsula el mensaje real transmitido al controlador PX4, que solo es compatible con MAVLINK.

En nuestro caso, se envían posiciones (PoseStamped), velocidades (Twist) y comandos (sevicios formados por mensajes personalizados, creados por MAVROS, con formato ROS). Esto, nos permite conectar el resto de aplicaciones con el script controlador, mediante *topics* comunes, de forma de que el script controlador se encargue de enviar la acción final al dron, mientras el resto de scripts se encarguen de resolver otras tareas.

De este modo, el teleoperador se diseña con el fin de generar comportamientos que se usarán en las fases finales del TFG. Sin embargo, para la primera versión, tan solo se construye una interfaz gráfica sencilla, encargada de enviar órdenes usando ROS que, en última instancia, llegan al dron y producen diversos comportamientos, tales como **moverse y girar**, a través de barras de acción.

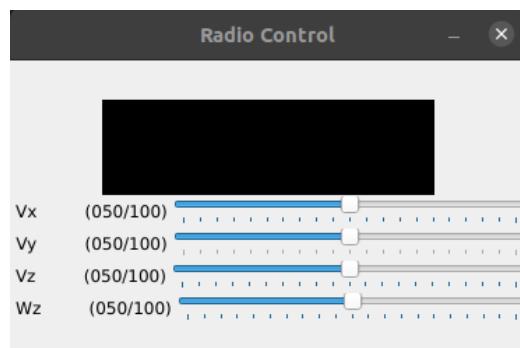


Figura 4.2: Primera versión del teleoperador

En la siguiente versión, se programan **comportamientos predefinidos**, es decir, acciones predeterminadas tales como desplazarse distancias concretas en ciertas direcciones, o girar un número específico de grados en un sentido u otro. Para ello, se diseña una ampliación sobre la interfaz anterior, en la que se añade un **botón por cada acción** concreta desarrollada, además de una **imagen de la cámara frontal** en tiempo real.

Por último, se afina el comportamiento de las acciones predefinidas, para hacer que el dron se desplace de celda en celda, concretamente de **centro en centro**. La idea de esto es que, el dron solo podrá tomar medidas de la señal en posiciones concretas y no en movimiento. Además, se agregan **marcadores en rviz**, para determinar las celdas visitadas (con colores aleatorios), junto con otro marcador que muestra la trayectoria que sigue la aeronave.

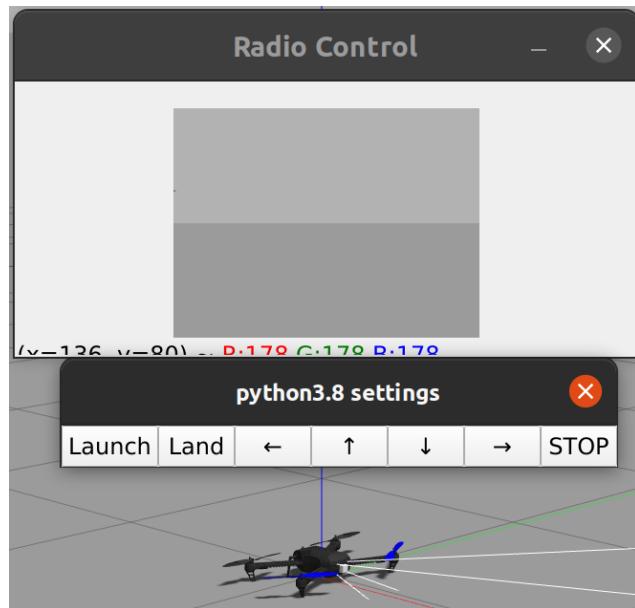


Figura 4.3: Versión final del teleoperador

A continuación, se muestra el “*main*” de la aplicación mencionada:

```

if __name__ == '__main__':
    try:
        rospy.init_node(NODENAME, anonymous=True)

        # Msgs
        ## Subscribers
        image_sub = rospy.Subscriber(IMAGE_TOPIC, Image, callback = image_cb)
        current_pos_sub = rospy.Subscriber(LOCAL_POSE_TOPIC, PoseStamped,
                                           callback = current_pos_cb)

        ## Publishers
        pos_pub = rospy.Publisher(RADIO_CONTROL_POS_TOPIC, PoseStamped,
                                  queue_size=10)
        cmd_pub = rospy.Publisher(RADIO_CONTROL_CMD_TOPIC, Px4Cmd,
                                  queue_size=10)

        # -- OPENCV --
        cv2.namedWindow(WINDOWNAME)

        # Buttons
        cv2.createButton('Launch', launch_button, None, cv2.QT_PUSH_BUTTON, 1)
        cv2.createButton('Land', land_button, None, cv2.QT_PUSH_BUTTON, 1)
        cv2.createButton('←', left_button, None, cv2.QT_PUSH_BUTTON, 1)
        cv2.createButton('↑', front_button, None, cv2.QT_PUSH_BUTTON, 1)
        cv2.createButton('↓', back_button, None, cv2.QT_PUSH_BUTTON, 1)
        cv2.createButton('→', right_button, None, cv2.QT_PUSH_BUTTON, 1)
        cv2.createButton('STOP', stop_button, None, cv2.QT_PUSH_BUTTON, 1)

        cv2.waitKey(0)
        cv2.destroyAllWindows()
    except rospy.ROSInterruptException:
        pass

```

Código 4.1: Main de center to center app

Donde, tras inicializar el nodo ROS, se definen por un lado los **suscriptores**, encargados de recibir los datos de la cámara y la posición del dron (usando MAVROS), los **publicadores**, cuya función es enviar posiciones y/o comandos al script controlador, y por último la **interfaz gráfica** diseñada con **OpenCV**, donde se define la ventana y los botones con las diversas acciones predefinidas¹.

¹Código completo en https://github.com/RoboticsLabURJC/2022-tfg-cristian-sanchez/blob/main/src/teleop/scripts/c2c_control.py

4.2. Modelo de propagación de señal

El siguiente paso consiste en generar un modelo de propagación de **señales RF**. Este apartado es especialmente relevante, ya que nos permite desarrollar una aplicación reactiva, con la idea de generar entornos en tiempo real, sobre los que probar nuestras soluciones.

Pero, antes de entrar en detalle en estos aspectos, conviene familiarizarse con algunos **conceptos básicos** sobre el **procesamiento de señales**:

1. *Señal*: se trata de una función que describe un fenómeno físico, y que se emplea para la transmisión de información.
2. *Dominio temporal*: establece el eje de abcisas con el tiempo.
3. *Dominio de la señal*: determina si la señal se expresa en tiempo o en frecuencia (a través de transformadas).
4. *Analog to Digital Converter (ADC)*: elemento electrónico que permite la conversión de señales analógicas a señales digitales.
5. *Received Signal Strength Indicator (RSSI)*: permite establecer el nivel de potencia de una señal, con respecto a 1 mW de potencia. Se expresa en dBm.
6. *Signal to Noise Ratio (SNR)*: métrica que permite medir la potencia de la señal con respecto al ruido ambiente.
7. *Frecuencia*: parámetro de la función que define a la señal, el cual determina el número de veces que se repite en un segundo. Se mide en hercios (Hz).
8. *TX*: Se refiere a la transmisión de la señal.
9. *RX*: Hace referencia a la recepción de la señal.

[32]

En cuanto al modelo de **propagación de señal**, se puede definir como un sistema capaz de calcular de que manera comporta la potencia de una señal, según las características de su entorno.

4.2.1. Aproximación de Friis

Por ello, se opta por emplear la aproximación de Friis, que nos proporciona una ecuación para modelizar nuestro problema:

$$P_r = P_t \cdot \left(\frac{G_t G_r \lambda^2}{(4\pi)^2 d^n L} \right) \quad (4.1)$$

Donde cada término significa lo siguiente:

1. P_t y P_r : aluden a la potencia del transmisor y la potencia del receptor respectivamente.
2. *Ganancias* (G_t , G_r): representan un valor incremental aplicado a la potencia de emisión y de recepción, respectivamente.
3. *Valor lambda* (λ): hace referencia a la longitud de onda. Está directamente relacionado con la frecuencia.
4. *Distancia* (d): desde el origen de la señal a un punto en el espacio.
5. L : representa todas aquellas pérdidas no asociadas a la propagación de la señal.
6. *Path-Loss Exponent* (PLE) (n): permite ajustar el modelo a diversos entornos. Es un valor constante extraido de forma empírica. A continuación se muestra una tabla con varios ejemplos.

[33]

Environment	Path Loss Exponent (n)
Free space	2
Urban area cellular radio	2.7 to 3.5
Shadowed urban cellular radio	3 to 5
Inside a building - line-of-sight	1.6 to 1.8
Obstructed in building	4 to 6
Obstructed in factory	2 to 3

Figura 4.4: Tabla ejemplos exponente n

Además, empleando este método, podemos modelizar las **pérdidas de una señal** estimadas durante su propagación, a través de la siguiente ecuación:

$$P_L(dB) = -10 \log_{10} \frac{\lambda^2}{(4\pi d)^2} \quad (4.2)$$

Sin embargo, para nuestro caso no es relevante (aunque se incluye dentro del módulo).

4.2.2. Módulo python de Friis

Una vez desarrollado lo anterior, lo siguiente consiste en encontrar la forma de que todo esto sea accesible para cualquier aplicación que lo deseé.

Por ello, surge la idea de crear un **módulo python** encargado de modelizar las ecuaciones previamente mencionadas. Para ello, se diseña una clase cuyo constructor recibe, por parámetros, las variables implicadas en las ecuaciones de Friis, además de las dimensiones del mapa y su resolución (la cual afecta al tamaño de celda).

Básicamente, el **proceso** a seguir para usar este módulo es el siguiente, primero se crea un objeto de la clase Friis donde se especifican las características de la señal y las variables relacionadas con el mapa, lo que genera internamente un array 2D vacío, que será rellenado en función del modelo seleccionado. Posteriormente, se selecciona el modelo deseado (propagación o pérdidas, este último no está testeado), pasando las coordenadas del origen de la señal por parámetros. Esto, retornará el mapa lleno con los valores asociados a las ecuaciones del modelo de Friis seleccionado.

A continuación se muestra un ejemplo sencillo de uso, donde se obtiene un mapa de propagación de señal, en forma de Numpy array 2D:

```

#! /usr/bin/env python
import friss as fr

if __name__ == '__main__':
    friis_object = fr.Friiss(power_tras=10.0,
                            gain_tras=1.5,
                            gain_recv=2.0,
                            freq=fr.FREQ_WIFI,
                            losses_factor=1.0,
                            losses_path=2.0,
                            world_sz=(10,10),
                            resolution=1.0)

    signal_map = friis_object.model_power_signal(origin=(5,3))

```

Código 4.2: Ejemplo básico de uso del módulo Friis

Concretamente, se genera un mapa 10x10 con resolución 1 (es decir, cada celdilla es de 1x1 unidades), de una señal WIFI, donde el transmisor emite a 10 W, con una ganancia de 1.5, el receptor posee una ganancia de 2, un factor de pérdidas (L) de 1, es decir, sin pérdidas, y por último, el exponente n (PLE) con un valor de 2, que representa el espacio vacío. Luego se genera el mapa de propagación de la señal, indicando que la fuente se encuentra en las coordenadas (5,3).

No obstante, este módulo posee **otras funcionalidades** útiles para trabajar con él, como son:

1. ***reset_world***: modifica el mapa que hubiera, estableciendo todos sus valores a cero.
2. ***get_world_sz***: retorna las dimensiones del mapa.
3. ***set_values***: modifica las características de la señal simulada.

Hay que tener en cuenta que, aunque se modifiquen los parámetros, se debe modelar de nuevo el mapa para que surtan efectos los cambios.

4.2.3. Aplicación de Friis

Finalmente y agrupando lo anterior, se integra el módulo previo, en una **interfaz gráfica intuitiva para el usuario**. La idea es estudiar, en tiempo real, como

evoluciona la señal cuando alguno de sus parametros, en la ecuación de Friis, es modificado.

Para ello, se emplea la librería **matplotlib**, debido a la enorme cantidad de herramientas de las que dispone, así como de su sencillez a la hora de crear nuevas aplicaciones. Funciona de manera que se generan eventos que son gestionados en “*callbacks*”, es decir, se generan bucles asociados a dichos eventos, que reaccionan a cambios en la interfaz generada.

En nuestro caso, la **estructura base** consta de una figura, sobre la que se agregan todos los elementos, entre los que encontramos los mapas de calor o “*heatmap*” en forma de plots, las barras de acción o “*sliders*”, botones, entre otros elementos que se explicarán más adelante.

Inicialmente, se opta por representar un mapa de calor con una barra de color asociada a los distintos valores de la señal. Además, se integran sliders correspondientes a cada valor presente en la ecuación de Friis, tal y como se muestra a continuación:

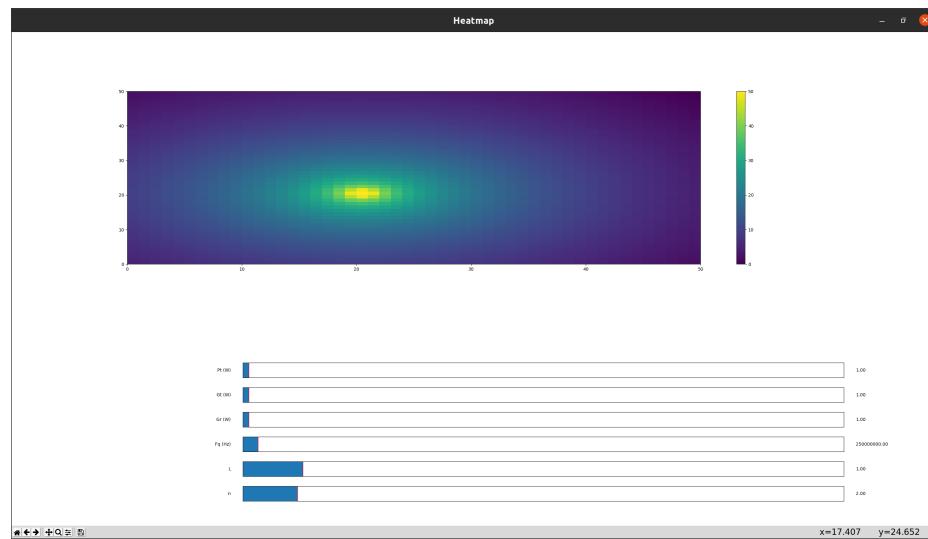


Figura 4.5: Primera versión de la interfaz

El problema es, que al actualizar los valores, también lo hace la representación, por lo que no se aprecia el efecto de los cambios en el plot.

Por ello, se decide agregar dos mapas de calor, uno con el máximo y el mínimo fijados a mano (donde sí se aprecian los cambios), y el anterior mencionado. Para elegir cual

usar, se añade una casilla marcable. Además, se incluyen dos variables relevantes a la hora de modelar, el **tamaño del mapa** y la **resolución**, manejadas a través de “*sliders*”, los cuales a su vez se activan al pulsar un botón de **SET**, que recarga la interfaz. Además, se ajustan los saltos de valores para que sean coherentes en el resto de barras de acción, tal y como se puede apreciar a continuación:

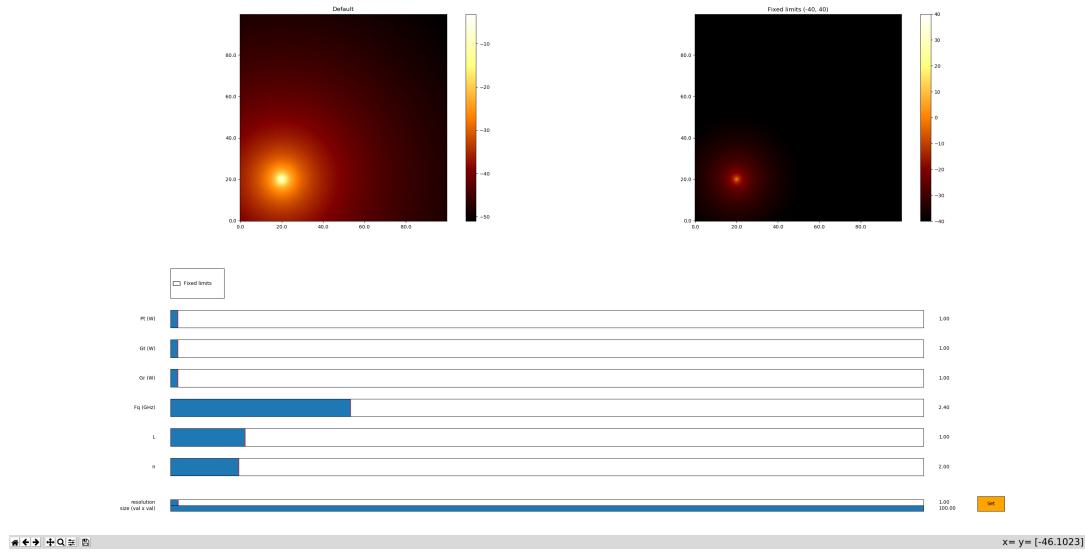


Figura 4.6: Versión final de la interfaz

Cabe destacar que, por motivos de desarrollo, no se ha añadido la parte de generación dinámica de obstáculos a la aplicación, ya que esta planteó como un extra al final del TFG.

4.3. Comportamiento sigue señal basado en RF

4.3.1. Introducción al problema

El problema a resolver en este caso, es el de detectar y navegar hacia una señal, empleando diversos algoritmos, para compararlos posteriormente. Por consiguiente, se ha realizado una integración conjunta de todos los puntos mencionados anteriormente.

Para ello, se ha diseñado una **aplicación servidor de datos**, que funciona como intermediaria con el módulo de Friis. Siendo concisos, dicha aplicación contiene **dos servidores** basados en **acciones ROS**, que son especialmente útiles en este caso, dada

su naturaleza asíncrona. Dichos servidores gestionan las peticiones para el dron y para rviz, tal y como se cuenta a continuación:

1. *Caso dron*: en términos generales, el dron envía su posición en coordenadas transformadas al sistema de referencia del “*heatmap*”, y recibe el valor de la señal de dichas coordenadas. En un caso real, el dron tan solo accedería al valor de la señal a través de un sensor que se lo permitiera. Además, se le ha agregado la funcionalidad de enviar, en dicha petición, si se deseaba un mapa con obstáculos o no, para compatibilizar el funcionamiento con entornos dinámicos.
2. *Caso rviz*: recibe una petición donde se agregan todas las características de la señal para generar el “*heatmap*” deseado, vease el origen y sus componentes. Esto, genera como respuesta un array de floats que contienen la información del mapa de calor, en un formato adecuado para su representación, es decir, para generar el mapa de forma gráfica, se emplea la biblioteca **grid_map**, que a través de un topic de ROS, permite enviar los datos a un plugin de rviz, el cual genera la representación visual buscada². También ha sido agregada la funcionalidad de los obstáculos para la experimentación futura.

4.3.2. Algoritmos

Antes de definir los algoritmos empleados, lo primero es determinar la base de la que se ha partido para desarrollarlos.

Por ello, inicialmente se ha definido una **clase “Drone”**, cuyo constructor se encarga de conectar los topics al controlador PX4 para comandar ordenes a la aeronave. Además, se encarga de establecer la comunicación con el servidor de datos (tanto para la potencia como para rviz) y define los diferentes atributos pertenecientes a la clase, que en este caso aluden a los parámetros necesarios para el funcionamiento de los algoritmos y la extracción de datos en los resultados.

En general, la clase sigue la siguiente estructura:

1. *Métodos para comandar al dron*: que se definen como el conjunto de funciones encargadas del movimiento del dispositivo (como despegar, aterrizar, desplazarse, entre otros). Mucha de esta funcionalidad ha sido adaptada del teleoperador comentado al de este capítulo.

²Toda la funcionalidad englobada en el directorio **heatmap_util** del proyecto

2. *Métodos de tolerancia*: encargados de establecer un margen aceptable entre la posición del dron y el objetivo deseado. Estos métodos permiten controlar con precisión problemas que surgen de la deriva y de condiciones externas, como puede ser el viento.
3. *Métodos de conversión*: que permiten transformar las coordenadas entre los distintos sistemas de referencia presentes en el problema, tal y como se puede apreciar a continuación.
4. *Algoritmos*: o las soluciones “sigue señal” propiamente dichas, que en sí, contienen el conjunto de métodos que cada cual necesita para llevarse a cabo. Se puede distinguir entre **manual**, **manual optimizado** y **Q-Learning**.

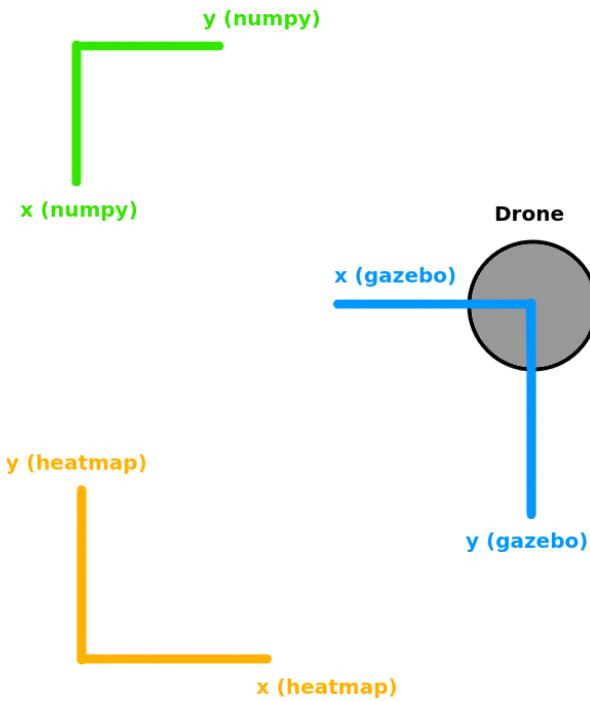


Figura 4.7: Sistemas de referencia

Por último y antes de entrar en los detalles de cada algoritmo, se deben cumplir una serie de premisas de cara a la simulación.

Estas son que, **todos los movimientos realizados por el dron deben estar contenidos en el mapa de calor generado**; además, **la medida de la señal sólo podrá tomarse cuando el dron esté en el centro de la celda**; los movimientos del

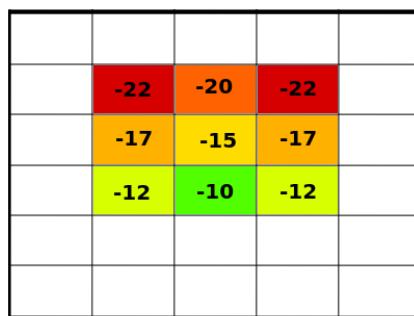
dron deberán ser **de centro en centro** aunque esto abarque más celdas de distancia (problema resuelto y adaptado del teleoperador); y que la métrica de cada celda es de 1x1 metros.

Algoritmo manual

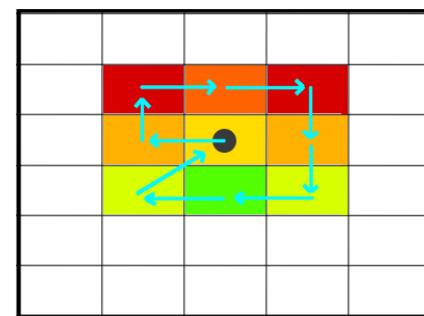
Es básicamente la primera aproximación, consiste en **visitar todos los vecinos más cercanos** y realizar el desplazamiento hacia las coordenadas del **vecino con mayor señal** medida.

La **condición de parada** analiza si las coordenadas objetivo de la iteración anterior, son las mismas que las coordenadas objetivo de la iteración actual, además, se debe cumplir que todos los vecinos colindantes tengan un valor de la señal menor.

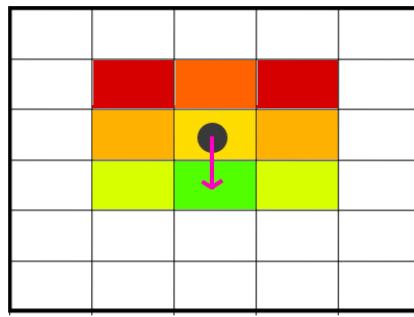
En cuanto a los métodos que se usan, se encuentra el de verificar movimientos válidos y el de comprobar si ha llegado a la casilla final, mediante la verificación anterior (vecindad con menor señal).



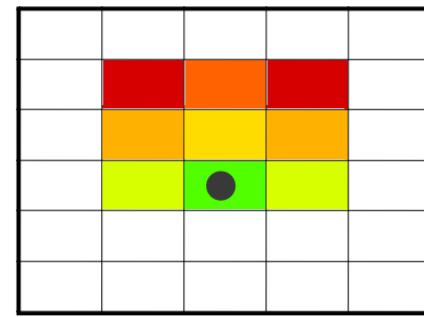
Valor de la señal



Extracción de información



Vecino con mayor señal



Resultado final

Figura 4.8: Representación algoritmo manual

Algoritmo manual (optimizado)

Tomando como referencia el algoritmo anterior, se han agregado ciertas mejoras y eficiencia. El principio es el mismo, se obtiene la información de los vecinos y se navega hacia el mejor candidato.

La diferencia radica en **no revisitar vecinos** cuya información se conozce. Para ello, se ha implementado un array que almacena hasta 18 coordenadas de vecinos visitados, de modo que solo se navega hacia coordenadas nuevas, y que por supuesto cumplan las condiciones del problema (no salirse del mapa de calor, moverse de centro a centro, entre otras).

La condición de parada es idéntica a la anterior, y los métodos usados también.

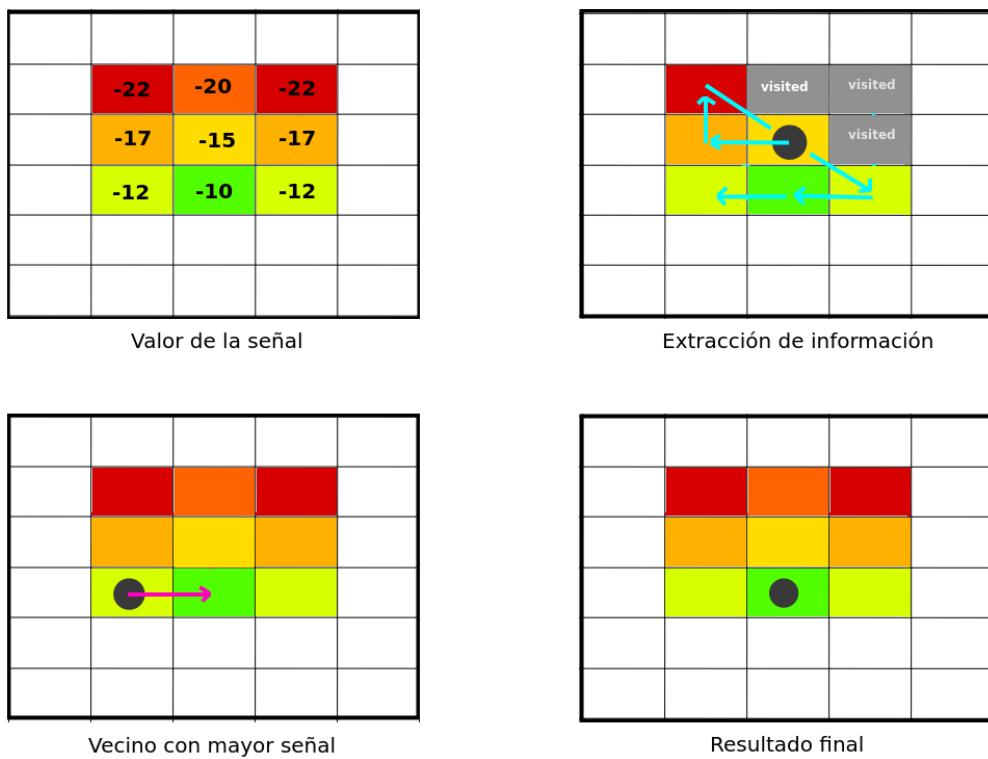


Figura 4.9: Representación algoritmo manual optimizado

Algoritmo Q-Learning

Por último, se ha planteado un algoritmo basado en técnicas de **aprendizaje por refuerzo**. Concretamente empleando Q-Learning, que tal y como comentamos al principio de la memoria, consiste en la obtención de una tabla Q, de estados y

acciones, donde se asignan valores numéricos cada acción según su estado, de modo que la acción más favorable acaba teniendo mayor valor numérico que el resto.

En nuestro caso, los **estados** son las coordenadas del dron en términos del mapa de calor, y las **acciones** son los **movimientos cardinales y diagonales**, de una o más celdas de distancia.

Como todo algoritmo de esta naturaleza, se distinguen dos fases: la **fase de entrenamiento**, cuyo objetivo es llenar de forma eficaz la tabla Q, y la **fase de inferencia**, donde se prueban los resultados obtenidos durante el entrenamiento.

Dentro del entrenamiento, podemos encontrar **episodios**, que en nuestro caso son las llegadas a la casilla final, o a casillas fuera del mapa definido (adicionalmente se añadió otra condición basada en el número de malas acciones consecutivas, pero de cara a extraer el máximo número de datos posibles para la tabla Q, esta condición no era adecuada, por ello se obvió); y las **iteraciones**, que se definen literalmente como la realización de una acción.

Además, para llenar el contenido de la tabla, se han definido las pertinentes **recompensas y penalizaciones** basadas en la diferencia entre la medidas, antes y después de realizar una acción (agregando un pequeño multiplicador a las recompensas negativas), contemplando casos extra, como cuando el dron se sale del mapa, donde se establece una recompensa fija negativa, calculada en proporción al resto de recompensas. Posteriormente, se asignan los valores obtenidos en la tabla Q, haciendo uso de la ecuación de Bellman:

$$Q(s, a) = (1 - \alpha) \cdot Q(s, a) + \alpha \cdot (r + \gamma \cdot \max_{a'} Q(s', a')) \quad (4.3)$$

Cabe destacar que, durante el entrenamiento, se especifican una serie de parámetros que han sido ajustados a través de la experimentación, estos son: el **número de episodios totales**, que repercute directamente en la *fase de exploración* (detallado a continuación); el **parámetro** α , o la tasa de aprendizaje, que afecta a la convergencia de las soluciones durante el aprendizaje; el **parámetro** γ , o factor de descuento, que alude a la importancia de las acciones futuras con respecto a las inmediatas; y por último los valores de **epsilon** (ϵ), que determinan si la acción tomada será aleatoria o extraída de la tabla, esto está directamente asociado a la *fase de exploración*, donde se prioriza la aleatoriedad con el fin de enriquecer con información la tabla Q.

En nuestro caso, esta fase ocupa un **20 % del número de episodios**, de forma lineal, es decir, que cada vez la prioridad se va decantando más del lado de la tabla y no de la aleatoriedad (durante el entrenamiento siempre se mantiene cierta posibilidad de tomar una acción arbitraria, para seguir actualizando los datos).

Para poder entrenar de forma eficiente, se han establecido distintos puntos de entrenamiento repartidos de forma uniforme por el mapa, tal y como se mencionará en la sección de métricas.

Los métodos usados para Q-Learning, se basan en las funcionalidades necesarias para desempeñar todo el proceso definido anteriormente, véase la generación de estados y acciones para la tabla, la extracción de índices dentro de la misma, el tratamiento del parámetro ϵ , la obtención de coordenadas válidas, entre otros³.

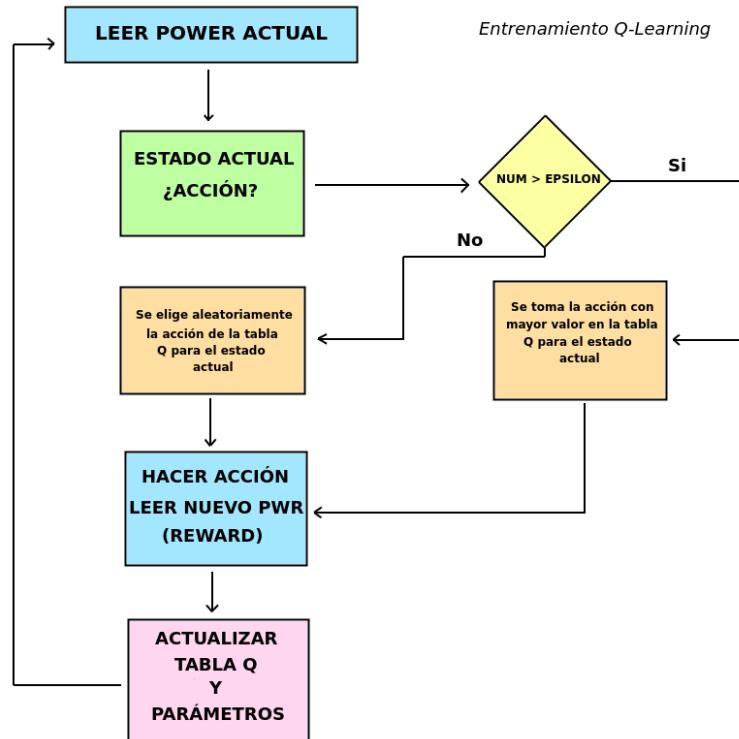


Figura 4.10: Esquema episodio fase de entrenamiento

Cabe destacar que, si la acción tomada lleva al dron hacia una condición de final, este finaliza automáticamente el episodio, viajando hacia una nueva posición

³Todos los métodos están explicados dentro del código <https://github.com/RoboticsLabURJC/2022-tfg-crystian-sanchez/blob/main/src/teleop/scripts/algorithms.py>

de entrenamiento y actualizando ciertos parámetros, como es el caso del parámetro ϵ . La condición de final se aplica siempre tras actualizar los valores intrínsecos en la iteración.

Por último, en la *fase de inferencia*, el dron analiza su estado (o sus coordenadas dentro del mapa de calor), y observa la mejor acción disponible dentro de la tabla Q ya rellena. Esto lo realiza hasta que detecta la condición de parada, que se cumple cuando la medida anterior de señal es mayor que la actual y todos los vecinos adyacentes a la mayor de las medidas, poseen señal inferior. Para hacer un correcto análisis, se parte siempre de coordenadas distintas a las que se usaron para entrenar y llenar la tabla Q.

4.3.3. Experimentos y resultados

Tipos de gráficos

Antes de entrar en las pruebas realizadas, es conveniente introducir el tipo de gráficos que han sido usados.

En primer lugar se encuentra el **mapa de puntos**. Aquí se muestran las posiciones en el mapa de calor donde el dron entrena, infiere (o desde donde empieza a moverse en los algoritmos), además de la posición de la señal y propios los límites del mapa.

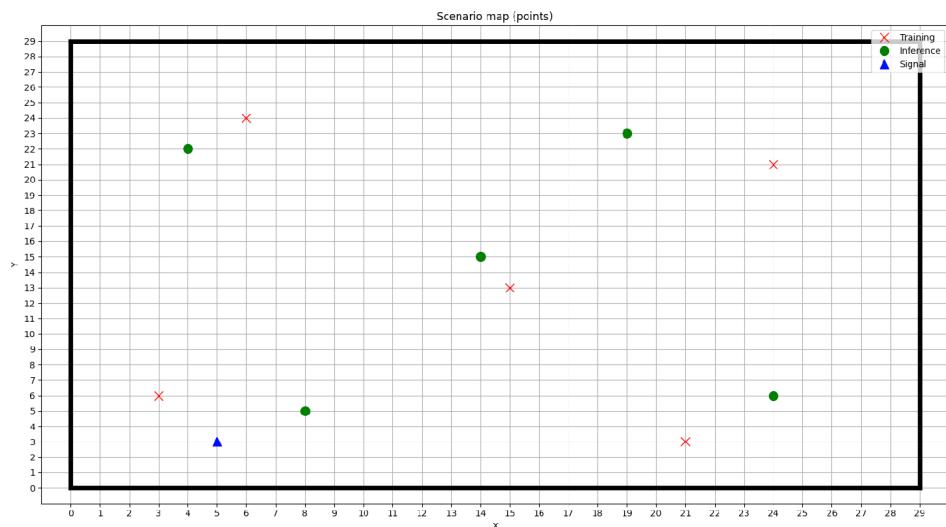


Figura 4.11: Mapa de puntos 30x30 con la señal en la esquina

El siguiente gráfico representa el **camino seguido** por el dron al aplicar cada

algoritmo para unas mismas coordenadas.

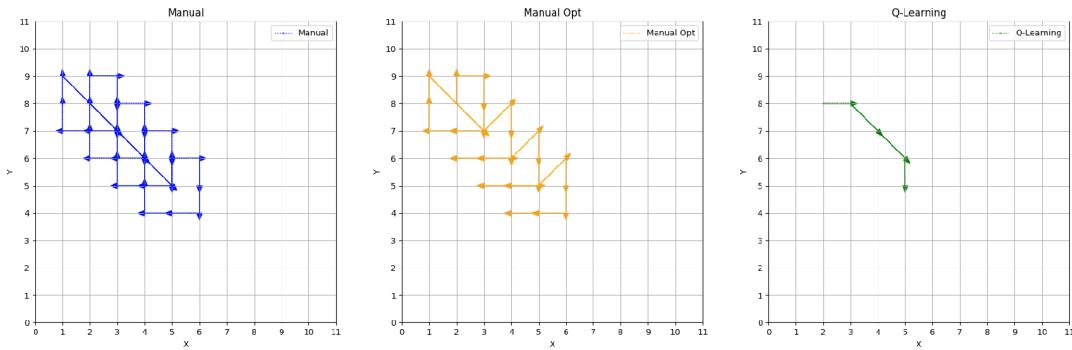


Figura 4.12: Trayectorias seguidas en mapa 12x12 con señal en el centro

A continuación se presenta uno de los gráficos más relevantes, en este caso, un gráfico triple que nos permite **conocer en detalle como ha ido el entrenamiento**. En concreto, representa tres métricas: el valor de **epsilon (ϵ)**, en el que se distingue la fase de exploración; la **recompensa acumulada**, que nos permite analizar la convergencia del entrenamiento; y el **número de iteraciones**, donde se observa que conforme el algoritmo aprende, el número se reduce. Todo ello con respecto a cada episodio.

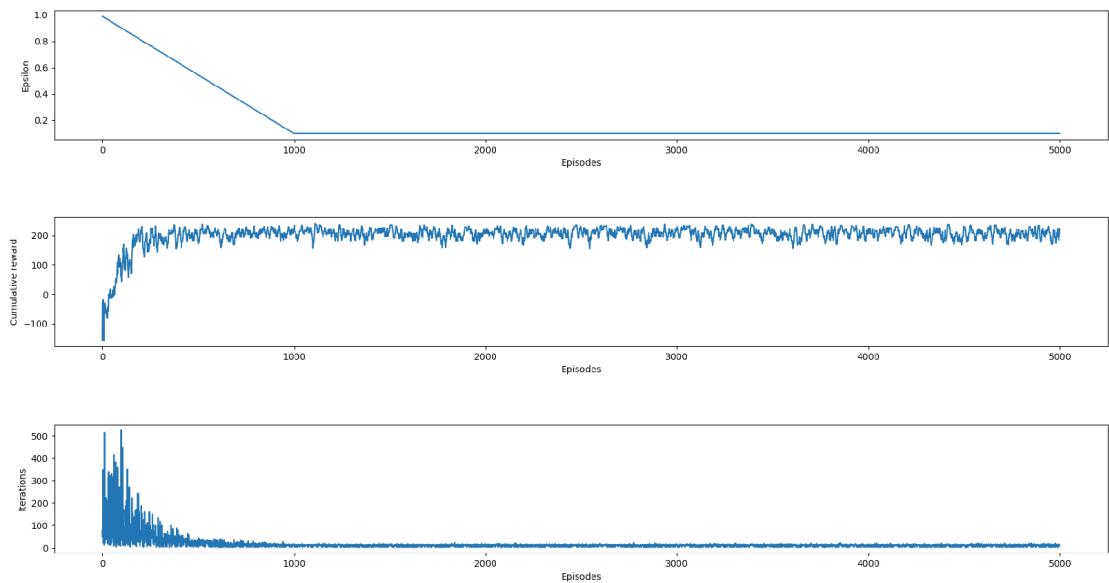


Figura 4.13: Gráfico de entrenamiento

Por último, se muestran los gráficos comparativos que nos dan un aproximado del **rendimiento** de cada algoritmo. En este caso, también se analizan tres cosas: el

tiempo medio en segundos que tarda el dron desde que despega hasta que vuelve a su posición de despegue; el **número medio de iteraciones** empleadas para alcanzar la señal; y el **número medio de movimientos** hacia coordenadas donde la señal es menor y no mayor⁴.

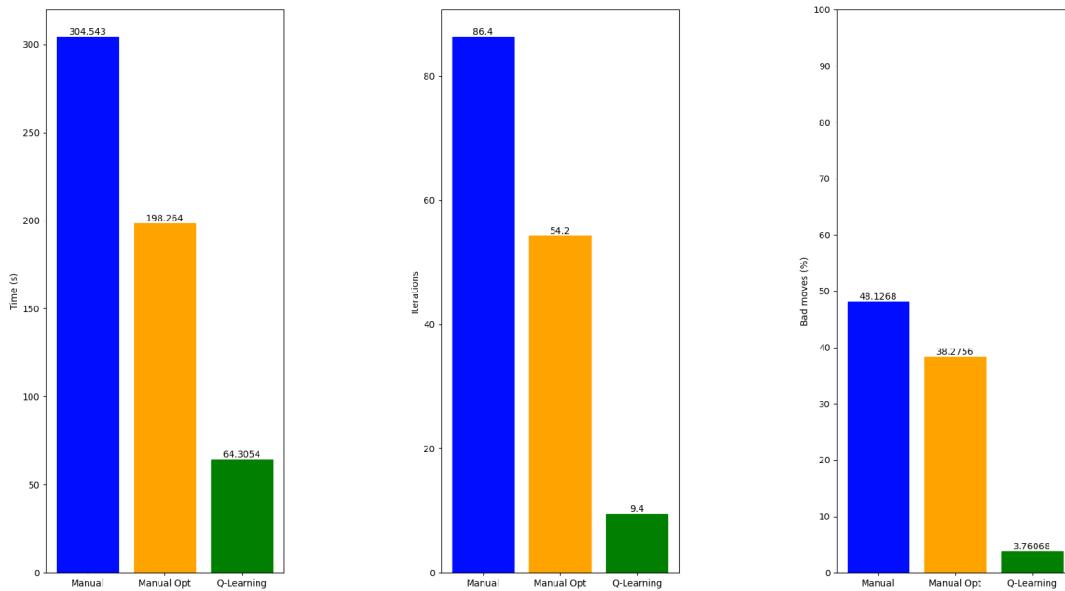


Figura 4.14: Gráficos comparativos

Experimentos realizados

En cuanto a las pruebas realizadas propiamente dichas, y a excepción del último caso, los parámetros de la señal siempre son los valores por defecto establecidos en la clase, donde sólo varía el tamaño del mapa, que se va modificando según el experimento. Además, cabe destacar que la señal se toma como un punto estático dentro del mapa de calor y con respecto al dron, distinguiendo la posición centrada y la posición cercana a una esquina, que también dependen del experimento.

```
def __init__(self, power_tras=1.0, gain_tras=1.0, gain_recv=1.0,
            freq=FREQ_WIFI, losses_factor=2.4, losses_path=2.0,
            world_sz=(50, 50), resolution=1.0):
```

Figura 4.15: Características de la señal por defecto

Primero se ha probado sobre un escenario de tamaño **12x12 metros**, con las dos posiciones de señal mencionadas:

⁴Los datos arrojados han sido guardados en formato *csv*.

Para la **señal cerca del centro**, situada en las coordenadas (5, 5) del “*heatmap*”, se puede ver el siguiente mapa para los puntos de entrenamiento e inferencia:

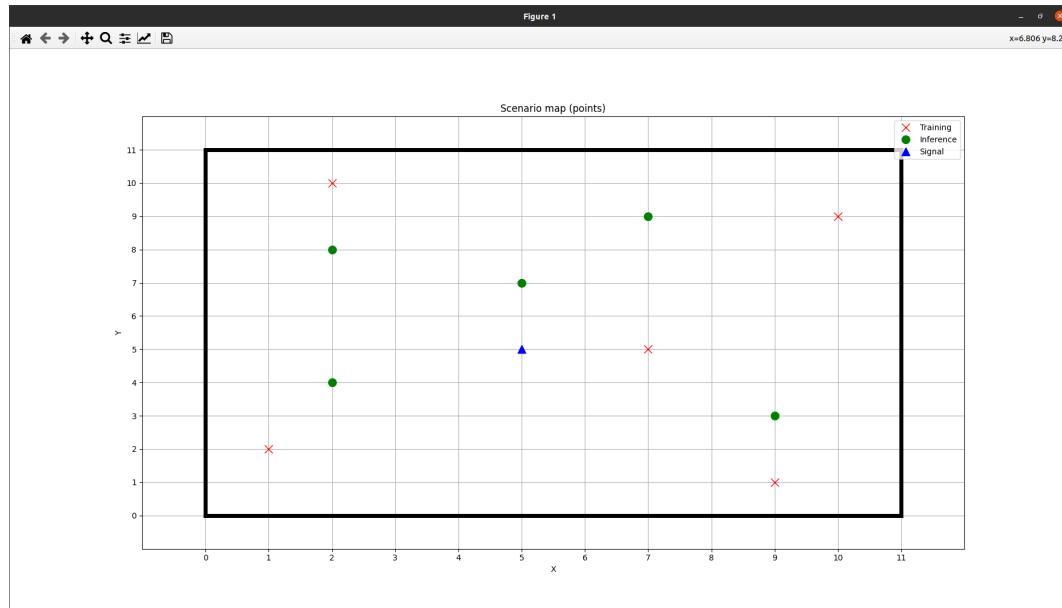


Figura 4.16: Mapa de puntos (12x12), señal centrada

Los resultados obtenidos arrojan que el algoritmo más eficiente es el de Q-Learning, ya que tarda menos tiempo, realiza menos iteraciones hasta llegar a la meta y tiene un porcentaje inferior de malas acciones, tal y como se puede ver a continuación:

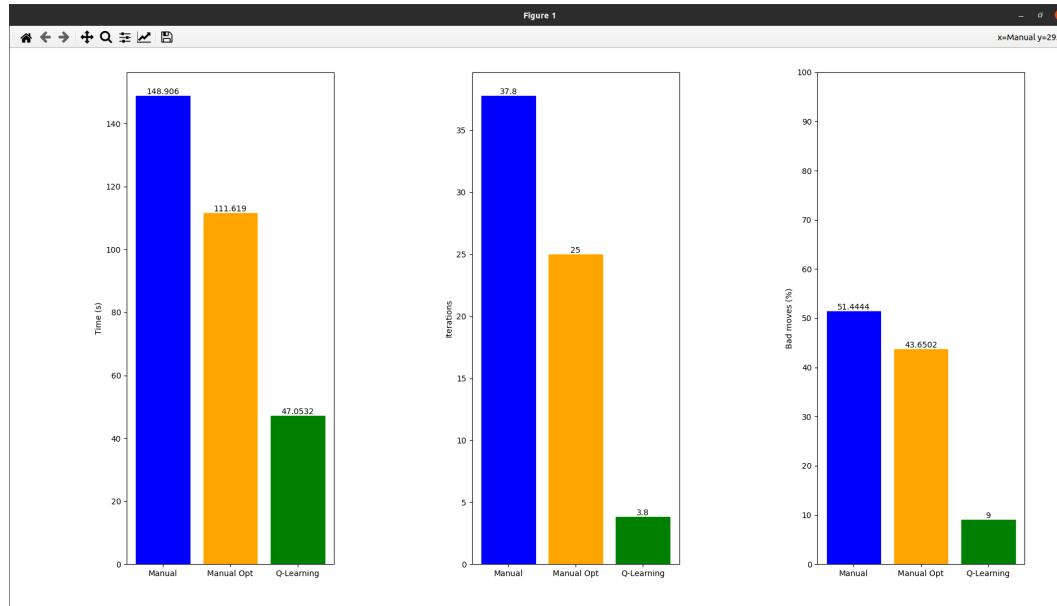


Figura 4.17: Comparativas (12x12), señal centrada

En el caso de la **señal cerca de la esquina**, la señal se sitúa en (3, 1) con respecto a las coordenadas del “*heatmap*”, siendo su mapa de puntos el siguiente:

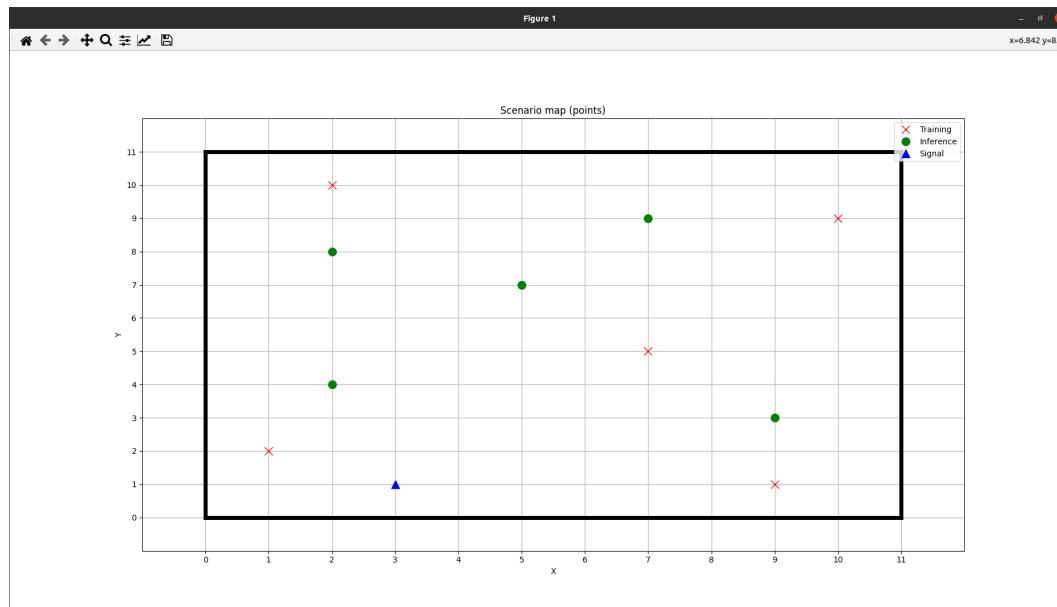


Figura 4.18: Mapa de puntos (12x12), señal en la esquina

En este caso, se obtiene la misma conclusión que en el escenario anterior, tal y como se ve a continuación:

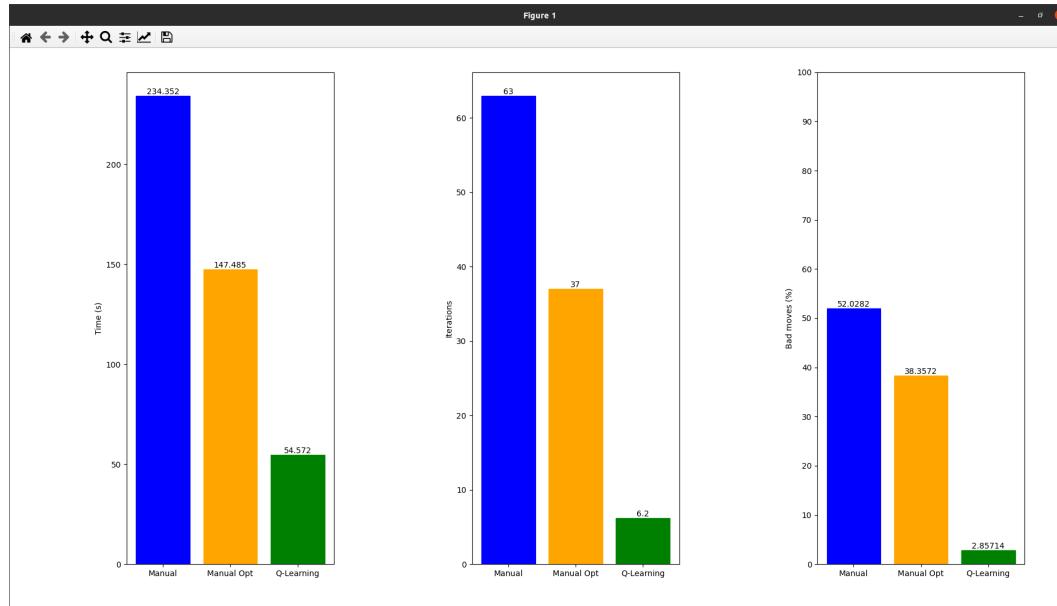


Figura 4.19: Comparativas (12x12), señal en la esquina

En segundo lugar, se incrementa el tamaño del mapa hasta **30x30 metros**.

Nuevamente, para la **señal cerca del centro** situada en este caso en las coordenadas (12, 12), tenemos:

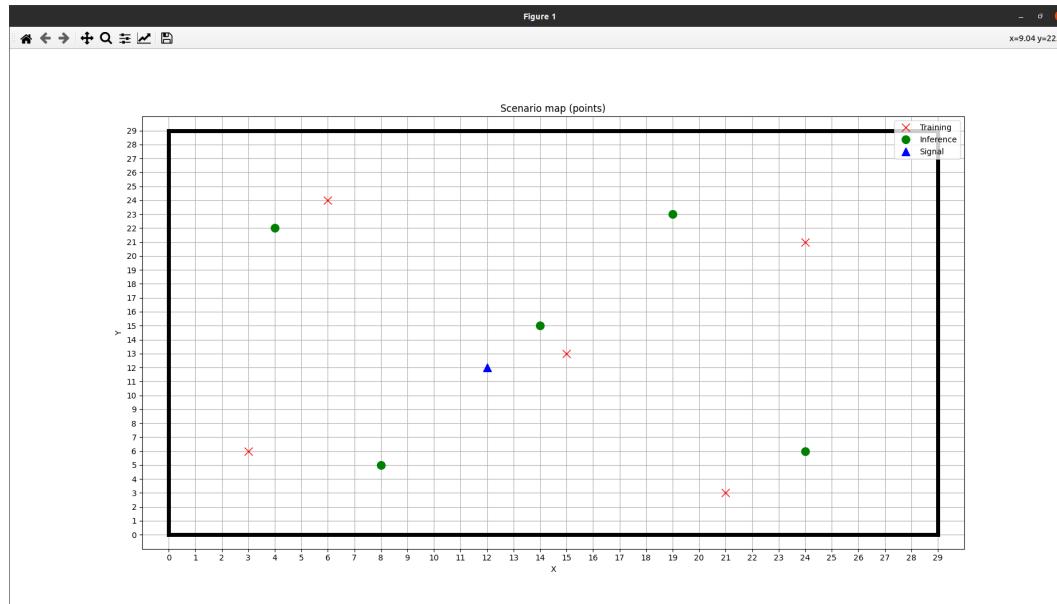


Figura 4.20: Mapa de puntos (30x30), señal centrada

En cuanto a los resultados, se concluye que el algoritmo de Q-Learning vuelve a ser la mejor opción, aunque se vea un incremento temporal y de iteraciones por el aumento

del tamaño del mapa, sigue siendo superior en todo al resto:

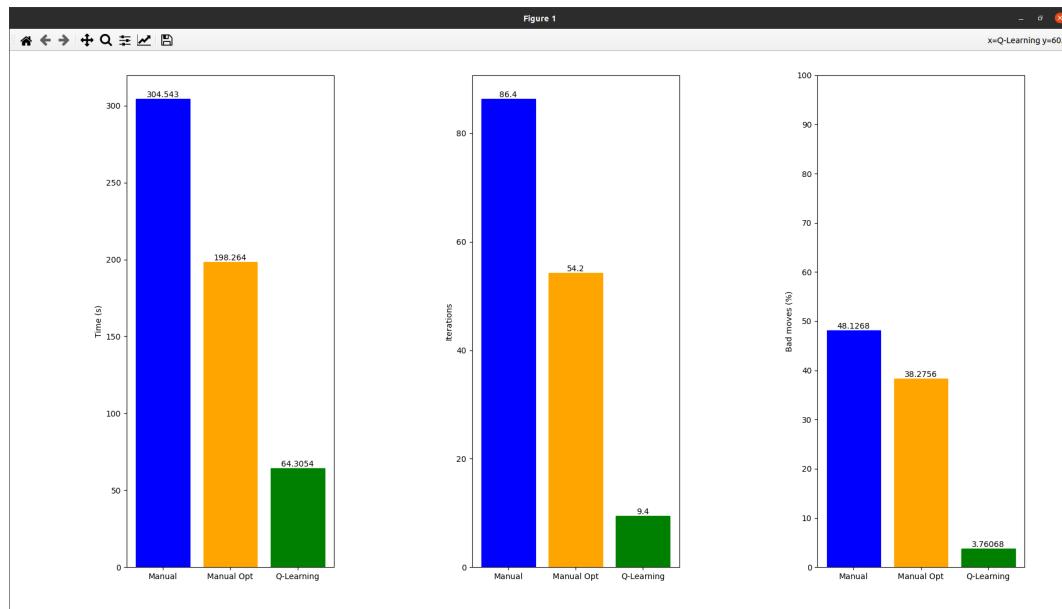


Figura 4.21: Comparativas (30x30), señal centrada

Continuando con la **señal cerca de la esquina**, que en este caso se encuentra en las coordenadas (5, 3), y donde su mapa de puntos es:

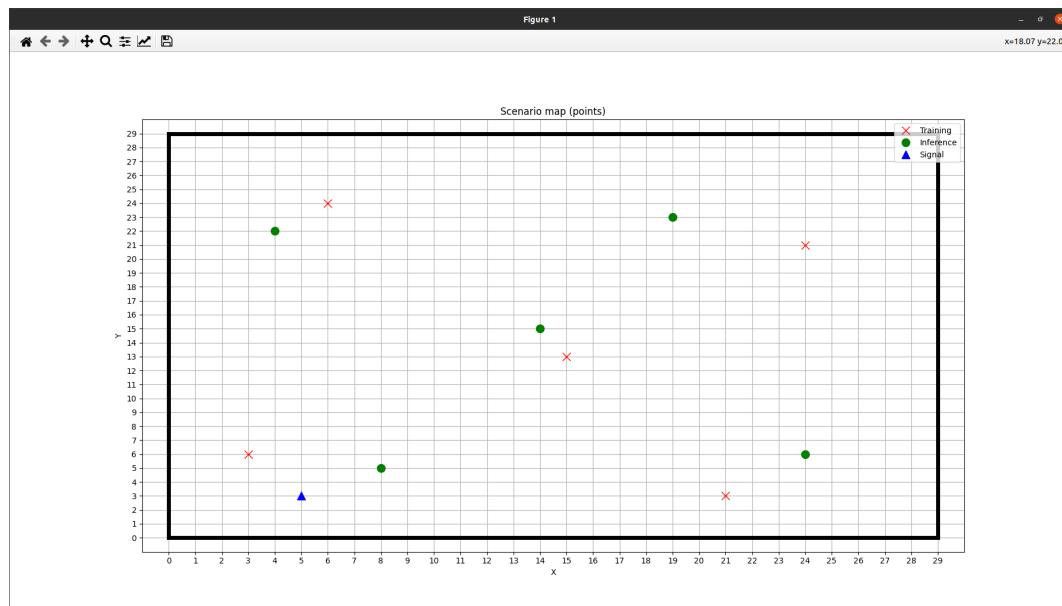


Figura 4.22: Mapa de puntos (30x30), señal en la esquina

Vemos que el resultado de aprendizaje por refuerzo es claramente nuevamente mejor

que el resto:

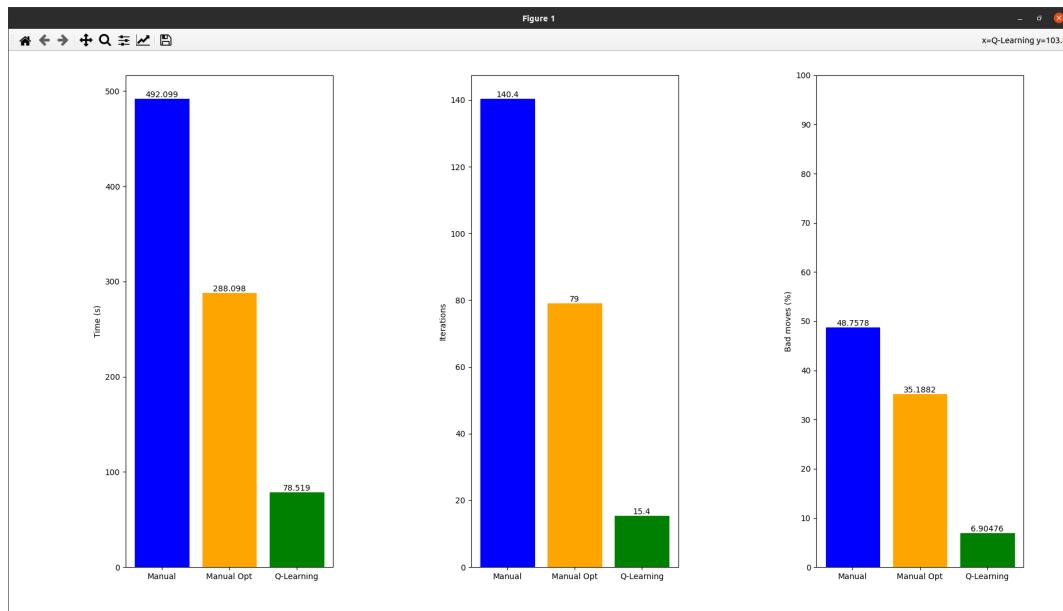


Figura 4.23: Comparativas (30x30), señal en la esquina

Finalmente, se ha realizado un experimento sólo para Q-Learning, en el cual se **entrena al modelo con una señal**, y se **realizaba inferencia con otra señal de características distintas**, aumentando la potencia del transmisor al doble y cambiando la frecuencia de Wi-Fi a 5G, pero manteniendo las coordenadas en las que se sitúa, que en este caso son (5, 3), lo que se ve en el siguiente mapa de puntos:

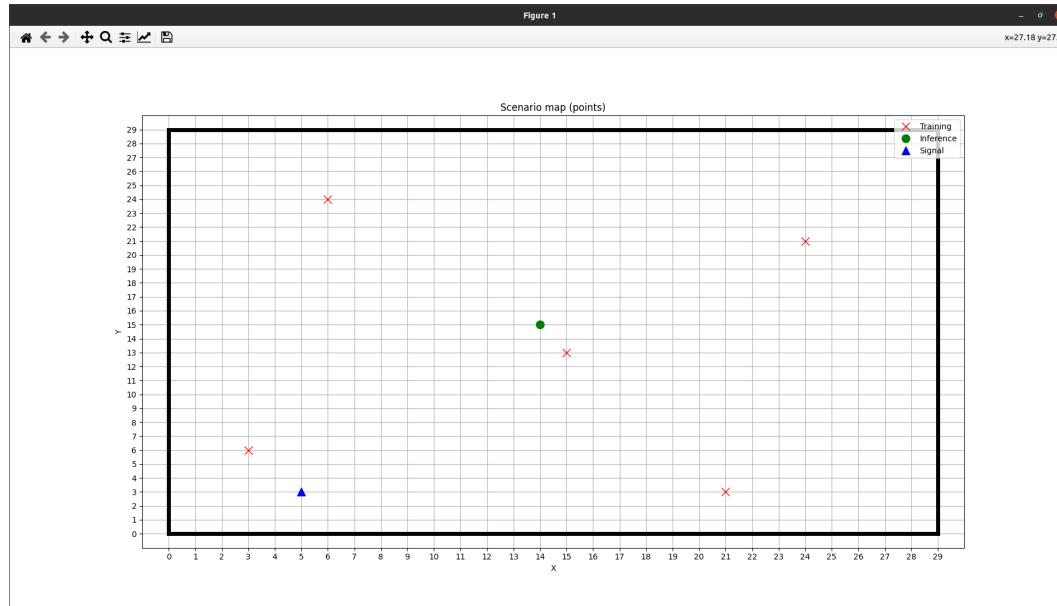


Figura 4.24: Mapa de puntos (30x30), señales diferentes

Para este caso, el problema se resuelve de igual forma para ambos casos, con una cierta variación irrelevante en la métrica temporal, derivada probablemente de la propia simulación:

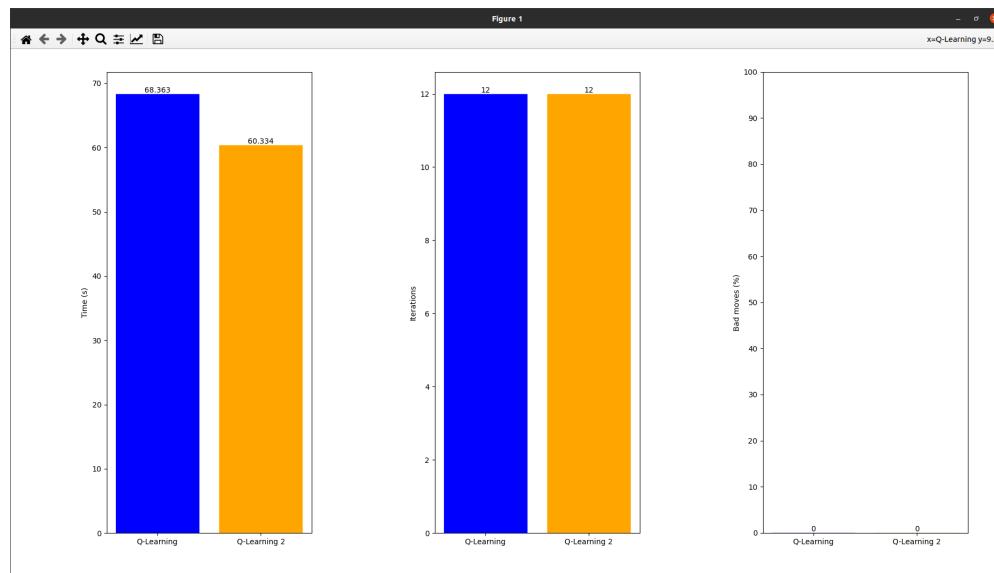


Figura 4.25: Comparativas (30x30), señales diferentes

4.4. Comportamiento sigue señal basado en RF en un entorno dinámico

4.4.1. Introducción al problema

El escenario planteado anteriormente, es una aproximación poco realista, es decir, en un **entorno real** se esperan perturbaciones y obstáculos. Por ello, se ha **implementado un escenario con muros que distorsionan la señal**.

Inicialmente, se ha establecido el mapa a mano, es decir, se han sobreescrito los valores degradados de la señal sobre el mapa original para simular un mapa con obstáculos.

4.4.2. Algoritmos

En cuanto a los algoritmos empleados, se parte de la idea de realizar un entrenamiento normal **sin obstáculos**, y ajustar el comportamiento a las situaciones emergentes.

Por ello se distinguen **dos casos**:

1. *El dron vuela por encima de la altura del obstáculo*: es decir, el dron navega por una zona con interferencias pero a una altura donde no exista colisión.
2. *El dron vuela a la misma altura que el obstáculo*: donde según que camino se escoja puede existir colisión.

4.4.3. Experimentos y resultados

Por ello, se observa que para el primer caso donde **el dron sobrevuela cualquier muro**, no existe inconveniente, puesto que el dron toma el camino que tomaría si no hubiera obstáculos. Esto es debido a que en inferencia, tan solo se tiene en cuenta su posición con respecto al mapa de calor, y por tanto no identifica si hay o no obstáculos.

En el otro escenario, donde el **dron vuela a la altura de los obstáculos**, se debe implementar un método de detección de obstáculos. En general, se puede generar un caso realista usando un láser LiDAR o una cámara 3D, pero para simplificar el problema, se ha empleado la información del mapa realizando una simulación del

comportamiento que tendría un sensor genérico de este tipo.

Por ello, primero se prueba excluyendo las acciones que desemboquen en colisión, donde se presupone que el entrenamiento evitará acciones que alejen al dron de la señal, tal y como se observa a continuación:

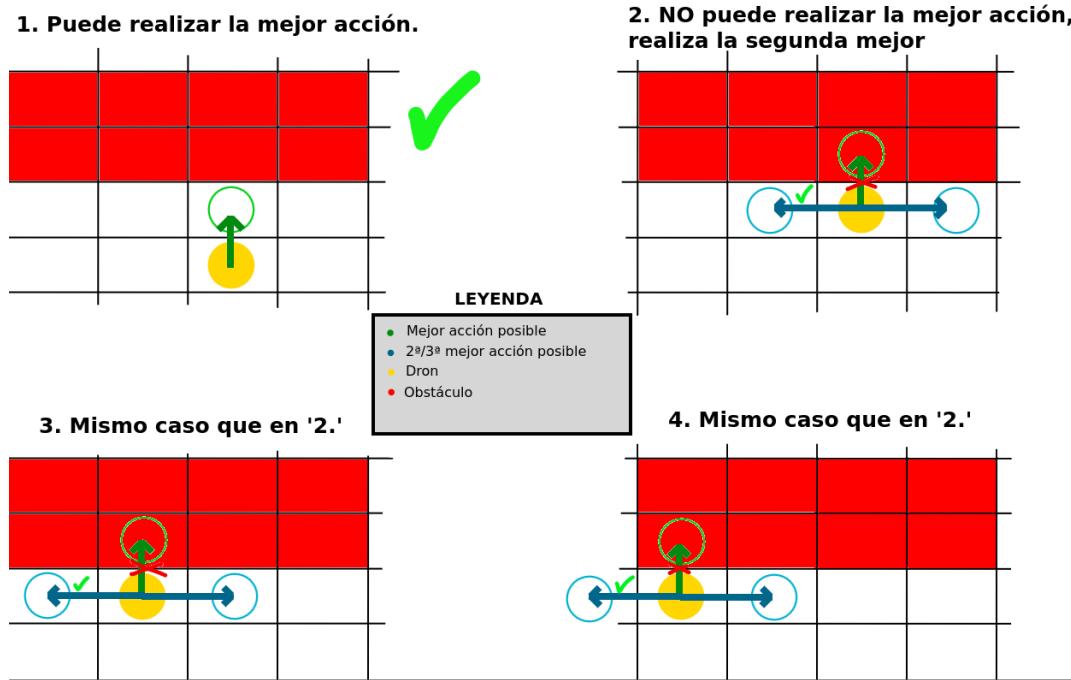


Figura 4.26: Simulación de sensor para obstáculo

Sin embargo, los resultados no son concluyentes, de modo que en ocasiones sorteaa el obstáculo, pero en otras simplemente retrocede o alcanza un mínimo local.

Por ello, y volviendo a la conclusión extraída del primer escenario, se ve la necesidad de aplicar un **comportamiento híbrido**, de modo que se navegue hacia la señal, hasta topar con un obstáculo lo suficientemente cercano, como para que cambie el modo de actuación para evitarlo. Una vez sorteado, se vuelve modo de navegación normal, hasta llegar a la señal o a otro obstáculo.

De este modo, se opta por emplear un algoritmo basado en *Virtual Force Field* (VFF), ... (RELENAR SI PROCEDE).

Capítulo 5

Conclusiones

En esta última sección, se comentarán las ideas extraídas tras el desarrollo del proyecto, así como el conocimiento obtenido y la posible continuación del mismo.

5.1. Objetivos cumplidos

Entre los objetivos planteados y resueltos encontramos los siguientes:

1. Desarrollo de una solución ROS para una aeronave no tripulada o dron.
2. Creación de una aplicación reactiva de simulación de señales, siguiendo el modelo de Friis, y empleando Matplotlib.
3. Extracción del mejor algoritmo (entre los probados), a través de métricas comparativas y experimentación, haciendo uso de Gazebo 11, rviz y técnicas de aprendizaje por refuerzo (Q-Learning).

5.2. Balance global y competencias adquiridas

En cuanto a los conocimientos adquiridos, podemos distinguir:

1. Desarrollo de aplicaciones usando OpenCV y Matplotlib.
2. Uso de plugins y trabajo con el modelo SDF del Iris Drone.
3. Creación de entornos personalizados empleando Gazebo 11.
4. Uso de marcadores y del módulo grid_map para rviz, así como su aplicación conjunta a través ROS en C++ y Python.
5. Empleo de PX4 y MAVROS para el control de la aeronave.
6. Desarrollo de soluciones basadas en Q-Learning a través de Python.
7. Adquisición de conocimientos relacionados al estudio de señales y su comportamiento.

5.3. Líneas futuras

Finalmente, y tal y como se comentó en la sección anterior, la manera de continuar este proyecto es haciéndolo más afín a entornos realistas, lo que implica agregar elementos como obstáculos y perturbaciones, así como añadir modos de funcionamiento para el dron que le permita mejorar su adaptabilidad.

Además, el mejor algoritmo según los resultados obtenidos alude a la solución por Q-Learning, sin embargo, se podría considerar emplear otras variantes (como empleando aprendizaje profundo) y comprobar si arrojan mejores resultados.

Capítulo 6

Anexo

A continuación se muestran las referencias a las figuras de este trabajo junto con la fuente de la que han sido obtenidas:

Referencia imágenes	Fuente de la que se ha obtenido
??	<p>1.https://revistaderobots.com/robots-y-robotica/que-es-la-robotica/?cn-reloaded=1</p> <p>2.https://www.elindependiente.com/vida-sana/2018/01/22/los-robots-que-nos-cuidaran-en-2050/</p> <p>3.https://www.iguanarobot.com/wp-content/uploads/2021/03/429190-1.jpg</p> <p>4.https://www.robotexplorador.com/</p> <p>5.https://www.edsrobotics.com/blog/robots-autonomos-que-son/</p>
??	<p>1.https://www.hogarmania.com/hogar/economia/como-elegir-mejor-robot-aspirador.html</p> <p>2.http://automata.cps.unizar.es/robotica/Morfologia.pdf</p> <p>3.https://www.aarp.org/espanol/salud/enfermedades-y-tratamientos/info-12-2013/cirugia-robotica-beneficios-riesgos.html</p> <p>4.https://www.nobbot.com/mars-home-planet-reto-mundial-colonizar-marte/</p>
??	https://elpais.com/eps/2023-05-27/robots-que-sienten-lo-que-tocan.html
??	http://www.technovelgy.com/ct/Science-Fiction-News.asp?NewsNum=455
??	https://www.medicalexpo.es/prod/hocoma/product-68750-438408.html
??	https://exoesqueleto/pediatrico/puede/comercializar

??	1. https://altertecnia.com/exoesqueletos-mejorar-productividad/ 2. https://www.eafit.edu.co/innovacion/spinoff/natural-vitro/PublishingImages/banner%20-exoesqueleto.jpg 3. https://www.marsibionics.com/atlas-pediatric-exo-pacientes/ 4. https://exoesqueleto-militar
??	1. https://shop.bihar.coop/es/inicio/34-exoesqueleto-flexible.html 2. https://exoesqueleto/rigido/movilidad
??	https://person-pose-keypoints
??	https://stm32cubeide.html
??	1. https://journals.sagepub.com/doi/full/10.1177/1687814017735791 2. https://cjme.springeropen.com/articles/10.1186/s10033-020-00465-z
??	https://www.atriainnovation.com/que-son-las-redes-neuronales-y-sus-funciones/
??	https://esquema/arbol/decision
??	https://movenet/pose/estimation
??	https://www.analyticsvidhya.com/blog/2022/03/pose-detection-in-image-usi
??	https://developers.google.com/mediapipe/solutions/examples

Cuadro 6.1: Anexo con las fuentes de donde se han obtenido las imágenes para este proyecto

Bibliografía

- [1] Daniel Dworakowski and Goldie Nejat. Robots understanding contextual information in human-centered environments using weakly supervised mask data distillation, 2020.
- [2] Jiefei Wang and Damith Herath. *What Makes Robots? Sensors, Actuators, and Algorithms*, pages 177–203. Springer Nature Singapore, Singapore, 2022.
- [3] Andrea Maiorino and Giovanni Gerardo Muscolo. Biped robots with compliant joints for walking and running performance growing. *Frontiers in Mechanical Engineering*, 6, 2020.
- [4] R. K. Nichols; H.C. Mumm; W.D. Lonstein; C. M. Carter; and J.P. Hood. *Chapter 13: Data Links Functions, Attributes and Latency*. New Prairie Press, 2018.
- [5] Leo Gugerty. Newell and simon’s logic theorist: Historical background and impact on cognitive modeling. *Proceedings of the Human Factors and Ergonomics Society Annual Meeting*, 50:880–884, 10 2006.
- [6] Max Christl. Vision-based autonomous drone control using supervised learning in simulation, 2020.
- [7] Y. Wang, R. Yoshihashi, R. Kawakami, et al. Unsupervised anomaly detection with compact deep features for wind turbine blade images taken by a drone. *IPSJ Transactions on Computer Vision and Applications*, 11(3):1–10, 2019.
- [8] Ahmad Taher Azar, Anis Koubaa, Nada Ali Mohamed, Habiba A. Ibrahim, Zahra Fathy Ibrahim, Muhammad Kazim, Adel Ammar, Bilel Benjdira, Alaa M. Khamis, Ibrahim A. Hameed, and Gabriella Casalino. Drone deep reinforcement learning: A review. *Electronics*, 10(9), 2021.
- [9] Yunlong Song, Mats Steinweg, Elia Kaufmann, and Davide Scaramuzza. Autonomous drone racing with deep reinforcement learning. In *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 1–8. IEEE, 2021.

- International Conference on Intelligent Robots and Systems (IROS)*, pages 1205–1212, 2021.
- [10] Beakcheol Jang, Myeonghwi Kim, Gaspard Harerimana, and Jong Wook Kim. Q-learning algorithms: A comprehensive classification and applications. *IEEE Access*, 7:133653–133667, 2019.
 - [11] Xinwei Chen, Marlin W. Ulmer, and Barrett W. Thomas. Deep q-learning for same-day delivery with vehicles and drones. *European Journal of Operational Research*, 298(3):939–952, 2022.
 - [12] Meisam Kabiri, Claudio Cimarelli, Hriday Bavle, Jose Luis Sanchez-Lopez, and Holger Voos. A review of radio frequency based localisation for aerial and ground robots with 5g future perspectives. *Sensors*, 23(1), 2023.
 - [13] Tiobe. *TIOBE Index for August 2023*. <https://www.tiobe.com/tiobe-index/>, 2023.
 - [14] SohomPramanick. *History of Python*. <https://www.geeksforgeeks.org/history-of-python/>, 2022.
 - [15] Python Source Fundation. *What is Python? Executive Summary*. <https://www.python.org/doc/essays/blurb/>, 2023.
 - [16] Bryce Limón. *Compiled vs interpreted language: Basics for beginning devs*. <https://www.educative.io/blog/compiled-vs-interpreted-language>, 2022.
 - [17] SohomPramanick. *History of C++*. <https://www.geeksforgeeks.org/history-of-c/>, 2022.
 - [18] IBM. *What is middleware?* <https://www.ibm.com/topics/middleware>, 2023.
 - [19] ROS. *ROS - Robot Operating System*. <https://www.ros.org/>, 2023.
 - [20] ros visualization. *RVIZ*. <https://github.com/ros-visualization/rviz#readme>, 2023.
 - [21] Gazebo. *About Gazebo*. <https://gazebosim.org/about>, 2023.
 - [22] Visual Studio Code. *Getting Started*. <https://code.visualstudio.com/docs>, 2023.

- [23] HTG Stuff. *What Is GitHub, and What Is It Used For?* <https://www.howtogeek.com/180167/htg-explains-what-is-github-and-what-do-geeks-use-it-for/>, 2016.
- [24] OpenCV. *About*. <https://opencv.org/about/>, 2023.
- [25] KattamuriMeghna. *Python / Introduction to Matplotlib*. <https://www.geeksforgeeks.org/python-introduction-matplotlib/>, 2023.
- [26] Peter Karanja. *How Drone Controllers Work (Explained for Beginners)*. <https://www.droneblog.com/drone-controller/>, 2023.
- [27] PX4 User Guide. *PX4 Autopilot User Guide (main)*. <https://docs.px4.io/main/en/>, 2023.
- [28] PX4 User Guide. *MAVLink Messaging*. <https://docs.px4.io/main/en/middleware/mavlink.html>, 2023.
- [29] PX4 User Guide. *ROS 1 with MAVROS*. <https://docs.px4.io/main/en/ros/ros1.html>, 2023.
- [30] JdeRobot. *JdeRobot*. <https://jderobot.github.io/>, 2023.
- [31] PX4 Autopilot. *Autonomous and Manual Modes*. https://docs.px4.io/main/en/getting_started/flight_modes.html, 2023.
- [32] UPM. *MOOC Software-Defined Radio 101 with RTL-SDR*. https://www.youtube.com/playlist?list=PL8bSwVy8_IcPCsBE71CYBLbQSS8ckWm6x, 2018.
- [33] Mathuranathan. *Friis Free Space Propagation Model*. <https://www.gaussianwaves.com/2013/09/friss-free-space-propagation-model/>, 2013.
- [34] Real Academia Española. *robótico, ca.* <https://dle.rae.es/rob%C3%B3tico#WYTncqf>, 2023.
- [35] Revista de Robots. *Robótica. Qué es la robótica y para qué sirve*. <https://revistaderobots.com/robots-y-robotica/que-es-la-robotica/?cn-reloaded=1>, 2023.
- [36] geeksforgeeks. *Industrial Robots*. <https://www.geeksforgeeks.org/industrial-robots/>, 2022.

- [37] geeksforgeeks. *Mobile Robots.* <https://www.geeksforgeeks.org/mobile-robots/>, 2022.
- [38] Bernard Marr. *The 4 Ds Of Robotisation: Dull, Dirty, Dangerous And Dear.* <https://bernardmarr.com/the-4-ds-of-robotisation-dull-dirty-dangerous-and-dear/>, 2021.
- [39] MiR. *AMR vs AGV - What's the difference?* <https://www.mobile-industrial-robots.com/insights/get-started-with-amrs/agv-vs-amr-whats-the-difference/>, 2023.
- [40] National Museum of the United States Air Force. *Kettering Aerial Torpedo “Bug”.* <https://www.nationalmuseum.af.mil/Visit/Museum-Exhibits/Fact-Sheets/Display/Article/198095/kettering-aerial-torpedo-bug/>, 2023.
- [41] de Havilland Aircraft Museum. *de Havilland DH82B Queen Bee.* <https://www.dehavillandmuseum.co.uk/aircraft/de-havilland-dh82b-queen-bee/>, 2023.
- [42] Mason B. Webb. *Operation Aphrodite.* <https://warfarehistorynetwork.com/article/operation-aphrodite/>, 2014.
- [43] srmconsulting. *¿UAV, UAS, RPA, dron... como llamarlos?* <https://srmconsulting.es/blog/uav-uas-rpa-dron-como-llamarlos.html>, 2021.
- [44] Brett Daniel. *Ground Control Stations: The Lifeblood of Remotely Piloted Aircraft.* <https://www.trentonsystems.com/blog/ground-control-stations>, 2020.
- [45] SAFEDroneFlying. *drone regulations.* <https://www.safedroneflying.aero/en/drone-guide/drone-regulations>, 2023.
- [46] A. M. Turing. Computing machinery and intelligence. *Mind*, 59(236):433–460, 1950.
- [47] Rockwell Anyoha. *The History of Artificial Intelligence.* <https://sitn.hms.harvard.edu/flash/2017/history-artificial-intelligence/>, 2017.
- [48] Sakshi Gupta. *Regression vs. Classification in Machine Learning: What's the Difference?* <https://www.springboard.com/blog/data-science/regression-vs-classification/>, 2021.

- [49] Stockfish. *About*. <https://stockfishchess.org/about/>, 2023.
- [50] Prateek Bajaj. *Reinforcement learning*. <https://www.geeksforgeeks.org/what-is-reinforcement-learning/>, 2023.
- [51] Brijesh Modasara. *Aprendizaje por refuerzo - Ejemplo práctico y marco*. <https://www.alexanderthamm.com/es/blog/refuerzo-aprendizaje-marco-y-ejemplo-de-aplicacion/>, 2023.
- [52] Prateek Bajaj. *Reinforcement and Punishment*. <https://pressbooks.online.ucf.edu/lumenpsychology/chapter/operant-conditioning/>, 2023.
- [53] B.F. Skinner. *Operant Conditioning*. <https://pressbooks-dev.oer.hawaii.edu/psychology/chapter/operant-conditioning/>, 2023.
- [54] OpenStax and Lumen Learning. *Reinforcement Learning Explained Visually (Part 4): Q Learning, step-by-step*. <https://towardsdatascience.com/reinforcement-learning-explained-visually-part-4-q-learning-step-by-step-b65>, 2023.
- [55] Wikiwand. *FM broadcast band*. https://www.wikiwand.com/en/FM_broadcast_band, 2023.
- [56] ECIT Engineering. *Friis Free Space Propagation Model Example*. https://www.youtube.com/watch?v=E-_oGNF3S-0, 2022.
- [57] antenna theory. *The Friis Equation*. <https://www.antenna-theory.com/basics/friis.php>, 2015.
- [58] Pedro Arias Pérez. *Infraestructura de programación de robots aéreos y aplicaciones visuales con aprendizaje profundo*. https://gsyc.urjc.es/jmplaza/students/tfm-drones-followperson-pedro_arias-2022.pdf, 2022.
- [59] Md Moin Uddin Chowdhury, Fatih Erden, and Ismail Guvenc. Rss-based q-learning for indoor uav navigation, 2019.
- [60] geeksforgeeks. *How to check if a given point lies inside or outside a polygon?* <https://www.geeksforgeeks.org/how-to-check-if-a-given-point-lies-inside-a-polygon/>, 2023.